Departamento de Ciências Exatas e Tecnológicas

Curso de Bacharelado em Ciência da Computação



SEGMENTAÇÃO DE IMAGENS RGB COM REDES NEURAIS

LUCIANA RONCARATI DOS SANTOS

Prof. Dr. César Alberto Bravo Pariente. (Orientador)

Ilhéus/2026

Sumário

- Introdução
- Objetivos
- Justificativa
- Metodologia
- Resultados e Discussões
- Pós processamento
- Conclusão
- Perspectiva de trabalhos futuros

Introdução

- Processamento de Imagens - Segmentação de Imagens
- Inteligência Artificial – Visão Computacional
- RNA’s (Redes Neurais Artificiais) - Arquitetura
- Aprendizado de Máquina(ML) e Profundo (DL)

Objetivo Geral

Apresentar um modelo de reconstrução 3D a partir das imagens segmentadas do ***Visible Human Project*** **(VHP)**, por meio da combinação de técnicas e métodos de processamento de imagens e de conceitos relacionados às Redes Neurais.

Objetivos Específicos

a) **Pré -processamento** - Criação de Máscaras (Rotulagem)

b) **Treinamento de modelo de rede neural** para efetuar a segmentação das 1877 imagens com 2048x1216 *pixels* e exportação de forma segmentada em área de interesse.

c) **Pós processamento** – Texturização do modelo 3D

Justificativa

A vantagem de usar redes neurais para segmentar a região de interesse do conjunto de dados **VHP - *Visible Human Project*** é a possibilidade de automatizar a segmentação, treinando a rede com uma amostragem do conjunto de dados e extrapolando para todas as imagens os parâmetros de treinamento.

Metodologia

Plataforma de Hardware e Software

- Notebook Dell Inspiron (Intel® Core™ i5-1235U, 16 GB RAM, Intel® Iris® Xe Graphics e SSD de 477 GB) plataforma VS Code, 3D Slicer e Meshlab de Linguagem *Python*.

- Google Colab (GPU Tesla T4, 12,7 GB RAM – 60GB armazenamento em disco)

VHP - Imagens e Máscaras

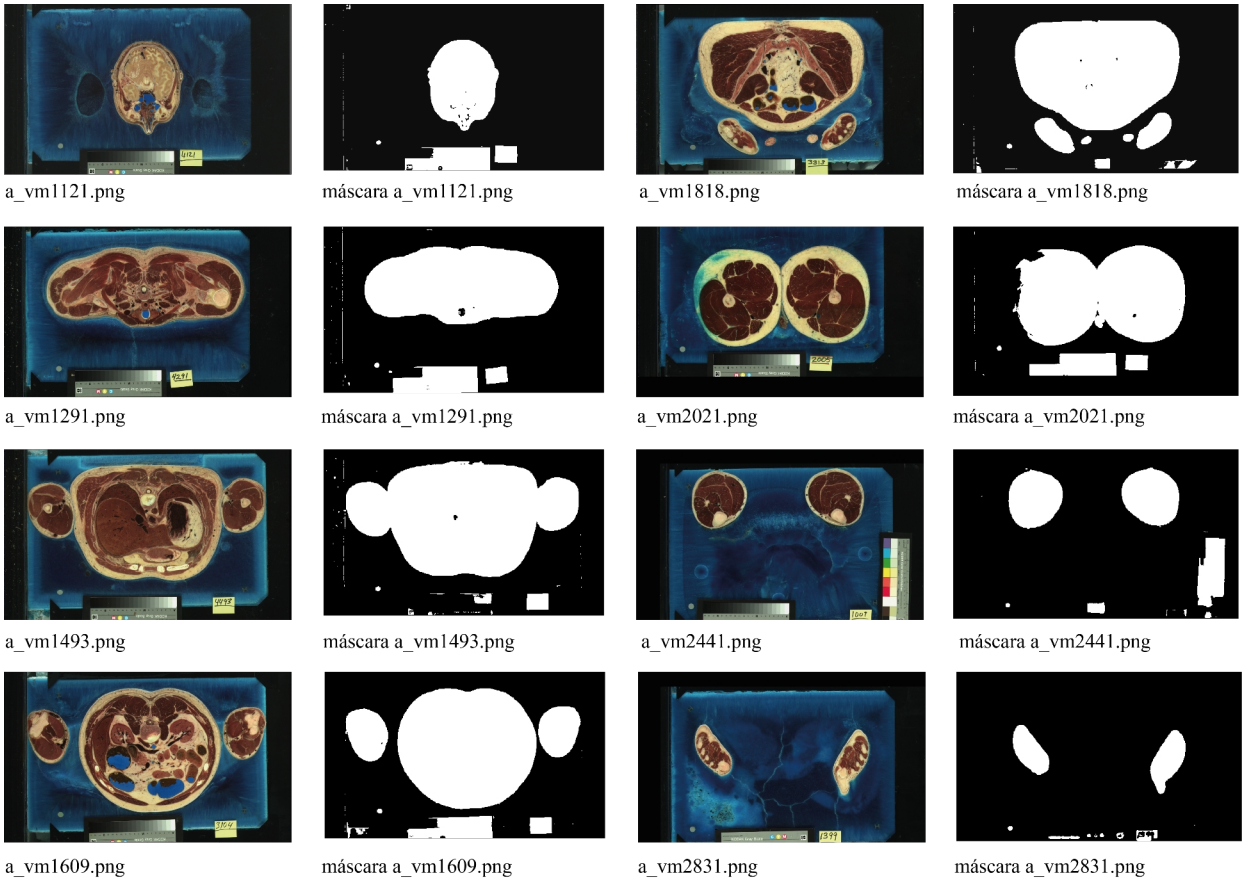


Fig.1- Imagens VHP originais e máscaras binárias -Preto (0)-FUNDO e Branco (1)-CORPO

Arquitetura CNN U-net

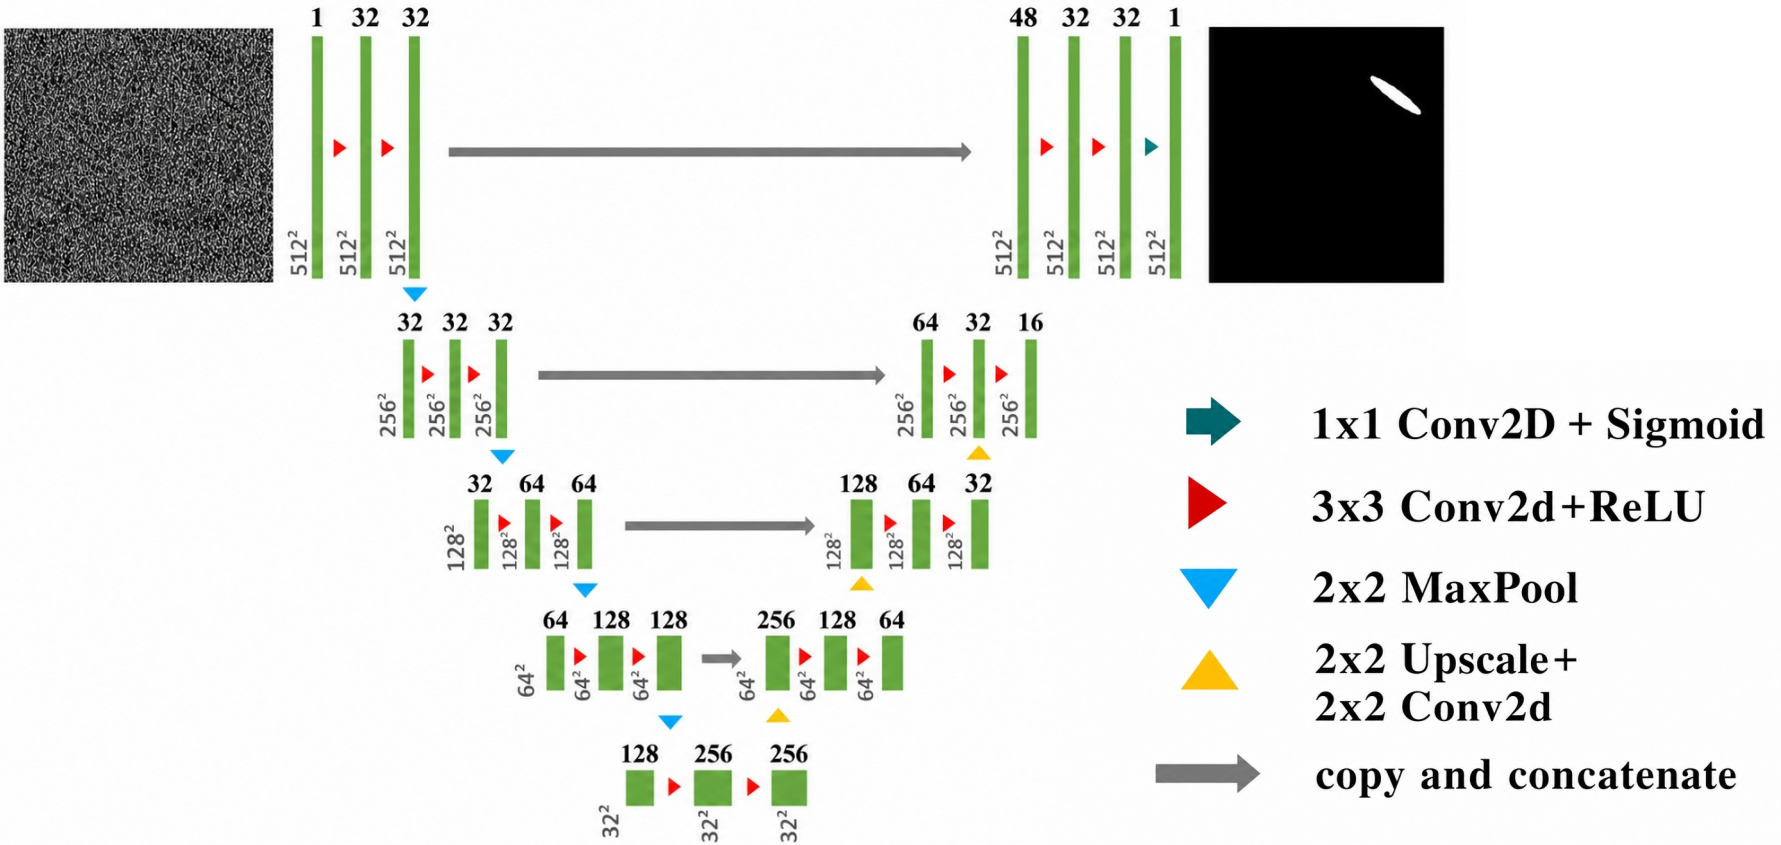


Fig.2- Arquitetura U-net – Fonte: Nvidia

Fluxo do Treinamento

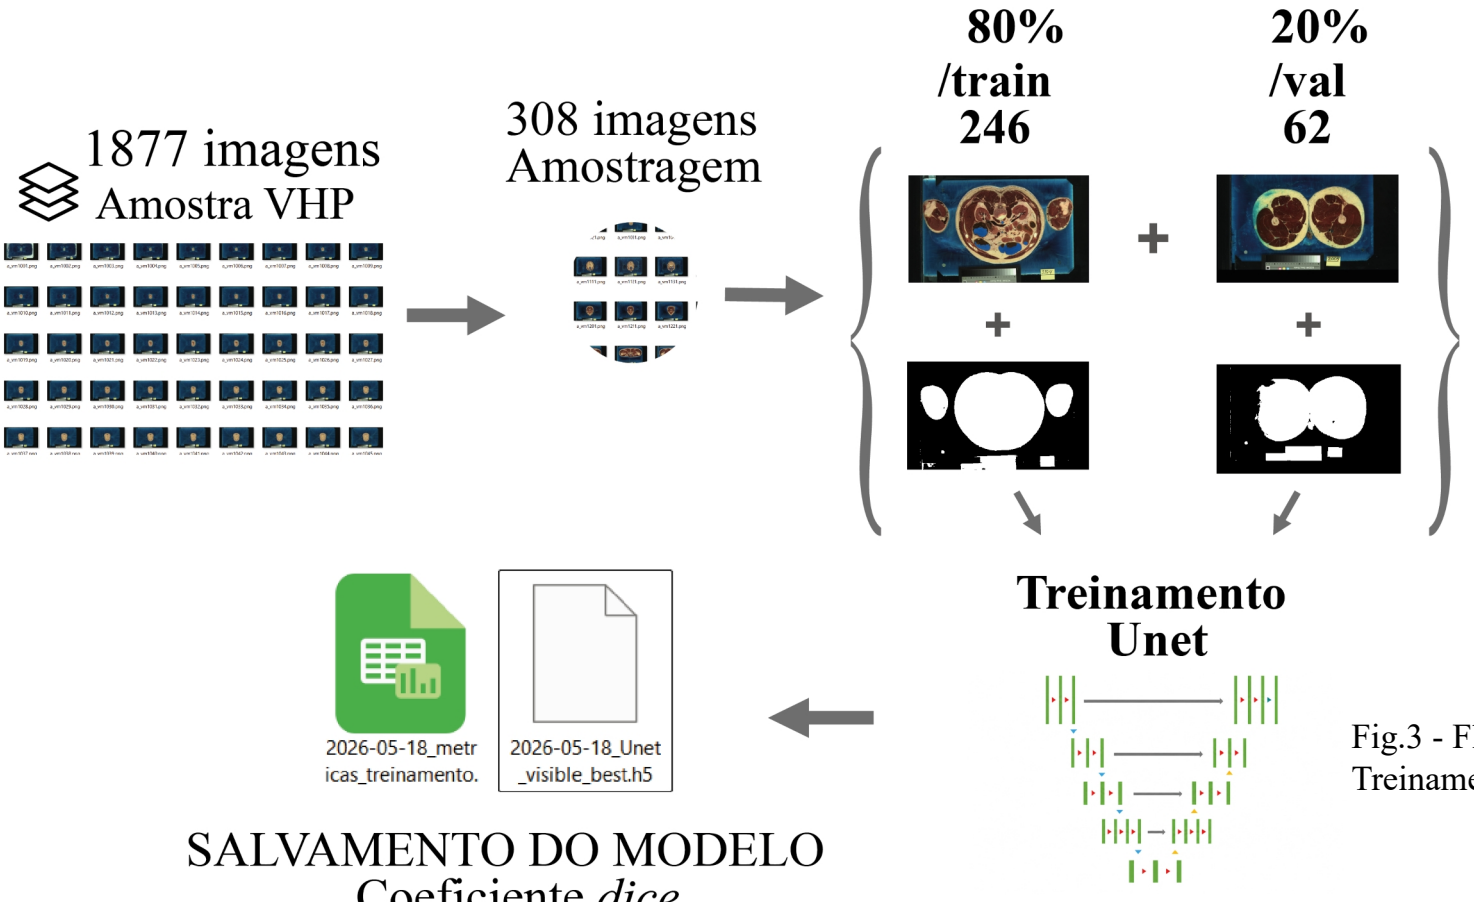


Fig.3 - Fluxo de Treinamento -Supervisionado

Métricas de Salvamento

BINARY CROSS ENTROPY - Entropia Cruzada Binária - ERRO

$$L_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)]$$

N = número total de pixels;

yi = valor real (ground truth) do pixel i, sendo 0 ou 1;

pi = probabilidade prevista pela U-Net para o pixel i pertencer ao objeto;

LBCE = valor da perda (erro).

Função Perda (BCE)

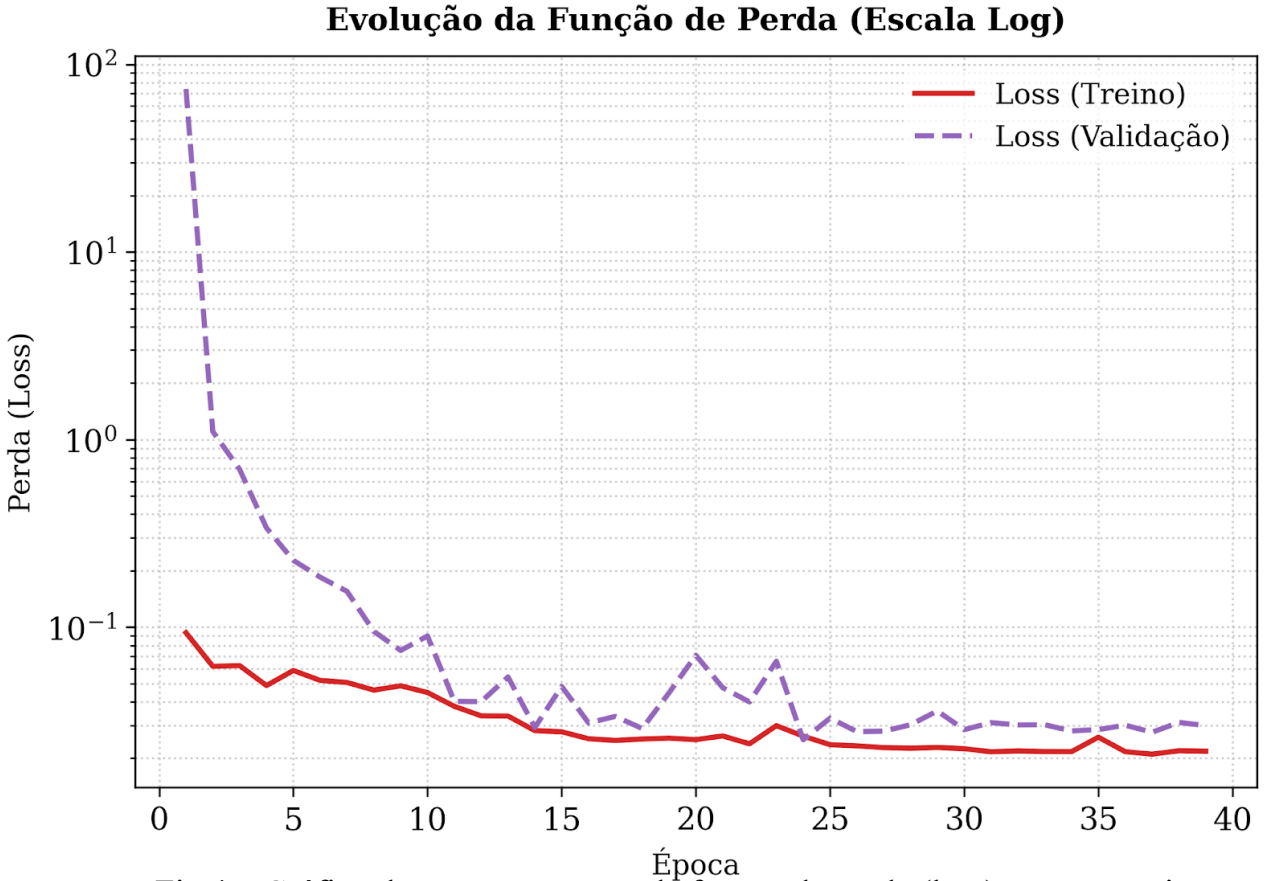


Fig.4 – Gráfico do comportamento da função de perda (loss) para os conjuntos de treinamento e validação.

Coeficiente Dice

Métrica utilizada para salvamento do melhor modelo de treinamento supervisionado (Rotulagem)

$$Dice = \frac{2 \times TP}{(2 \times TP) + FP + FN}$$

TP = Verdadeiro Positivo

FP = Falso Positivo (considera o ruido)

FN = Falso Negativo(ignora pele)

IoU - Intersection over Union

- Métrica utilizada para avaliar o desempenho de modelos de segmentação de imagem
- IoU- Mede a sobreposição entre a segmentação predita pelo modelo e a segmentação real

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

$$Dice = \frac{2 \cdot IoU}{IoU + 1}$$

Métricas de Performace

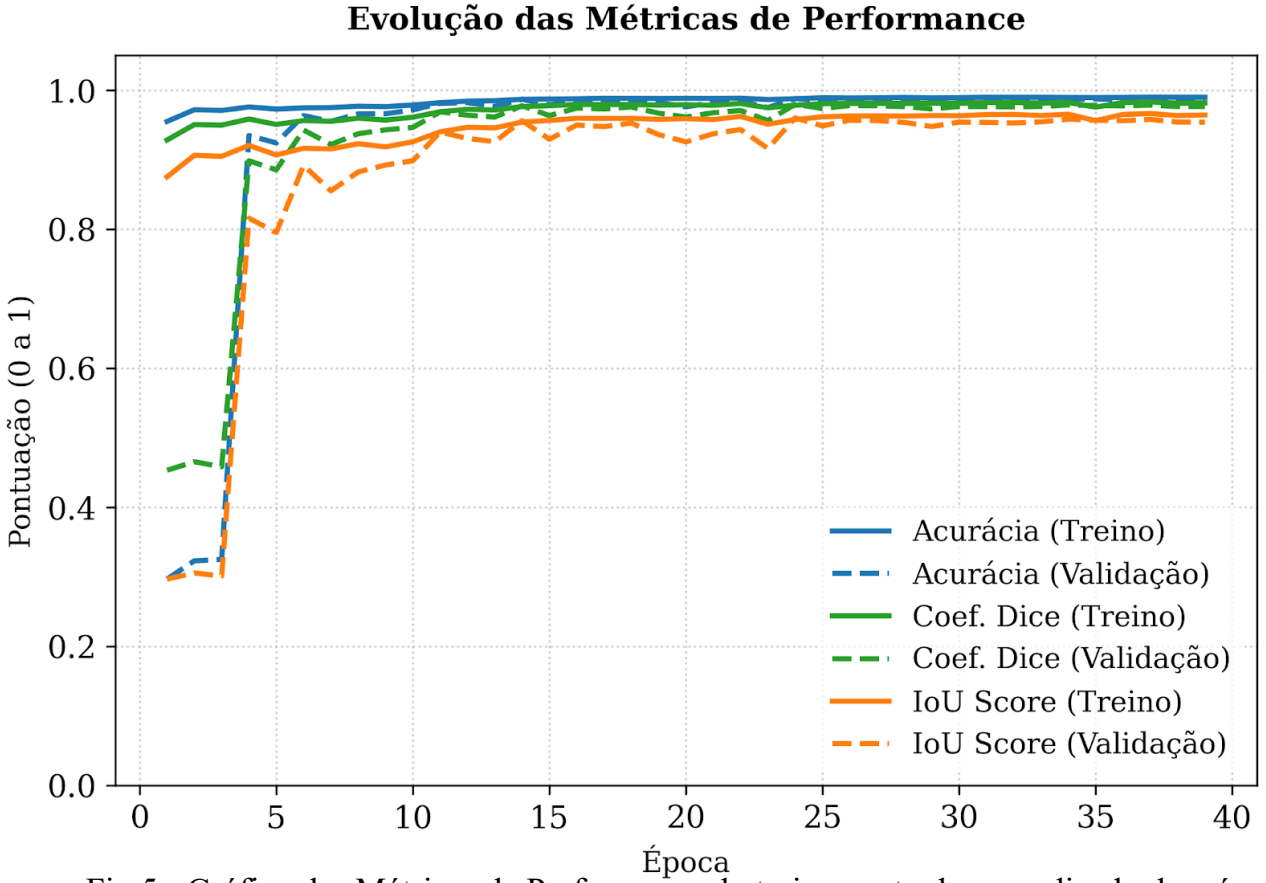


Fig.5 - Gráfico das Métricas de Performance do treinamento de aprendizado de máquina

Resultados e Discussões

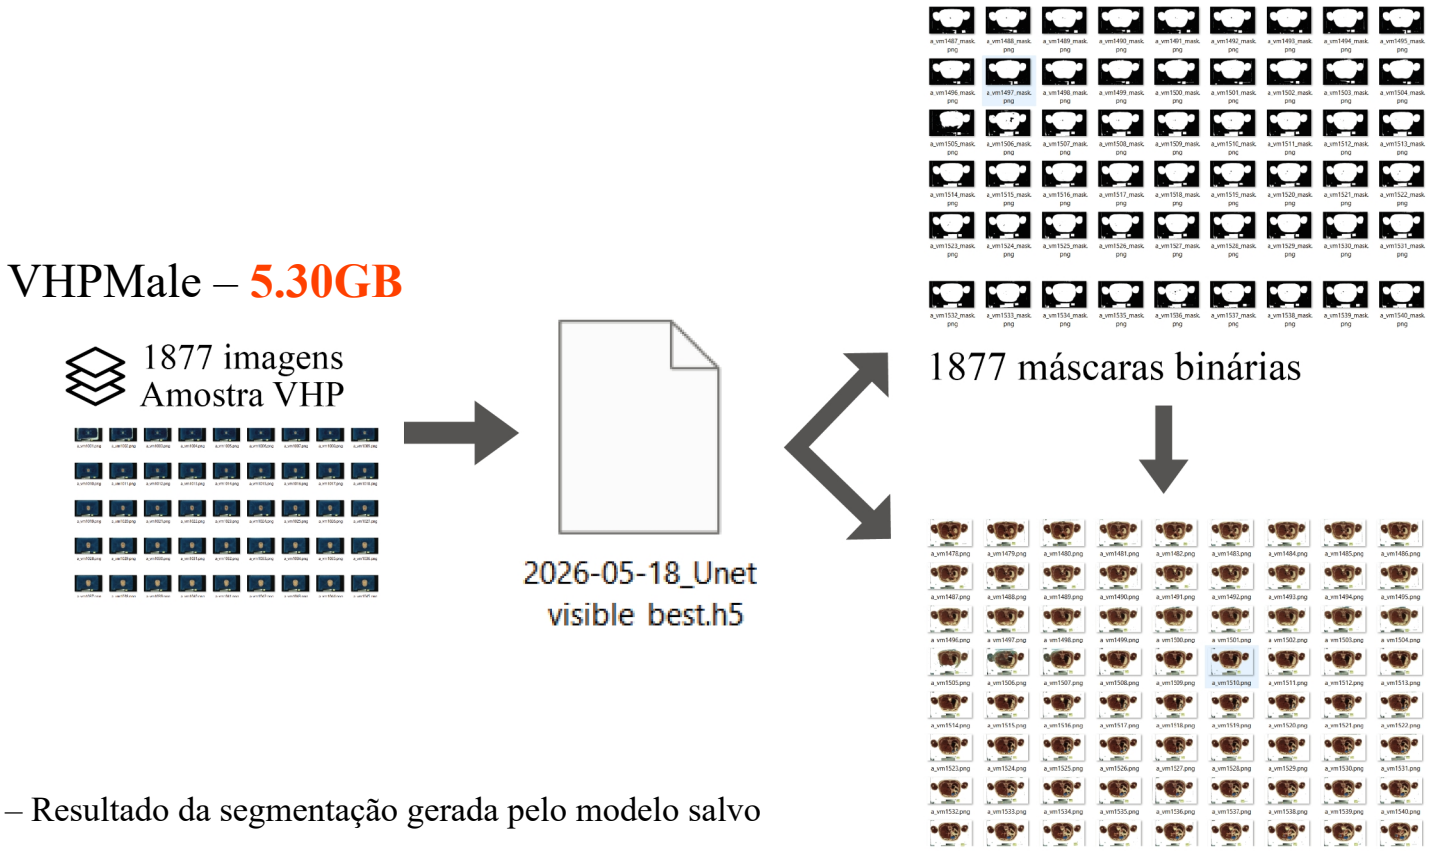
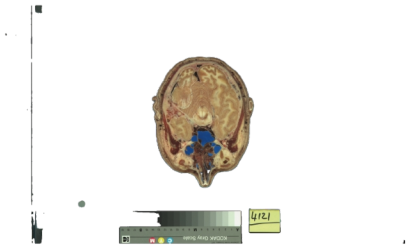


Fig.6 – Resultado da segmentação gerada pelo modelo salvo

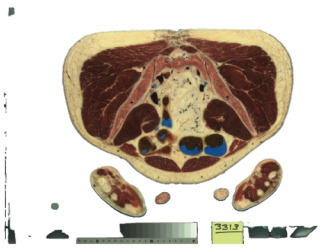
Imagens sem fundo azul



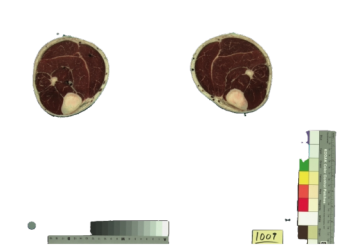
a_vm1121.png



a_vm1493.png



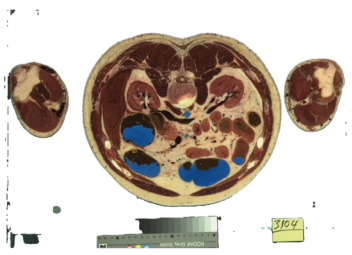
a_vm1818.png



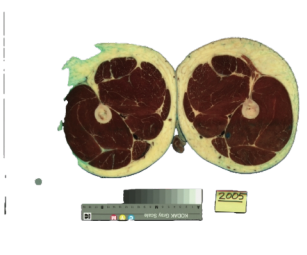
a_vm2441.png



a_vm1291.png



a_vm1609.png



a_vm2021.png



a_vm2831.png

Fig.7 - Imagens segmentadas sem fundo azul – resultado da aplicação do modelo de treinamento salvo

Reconstrução 3D – Img segmentadas

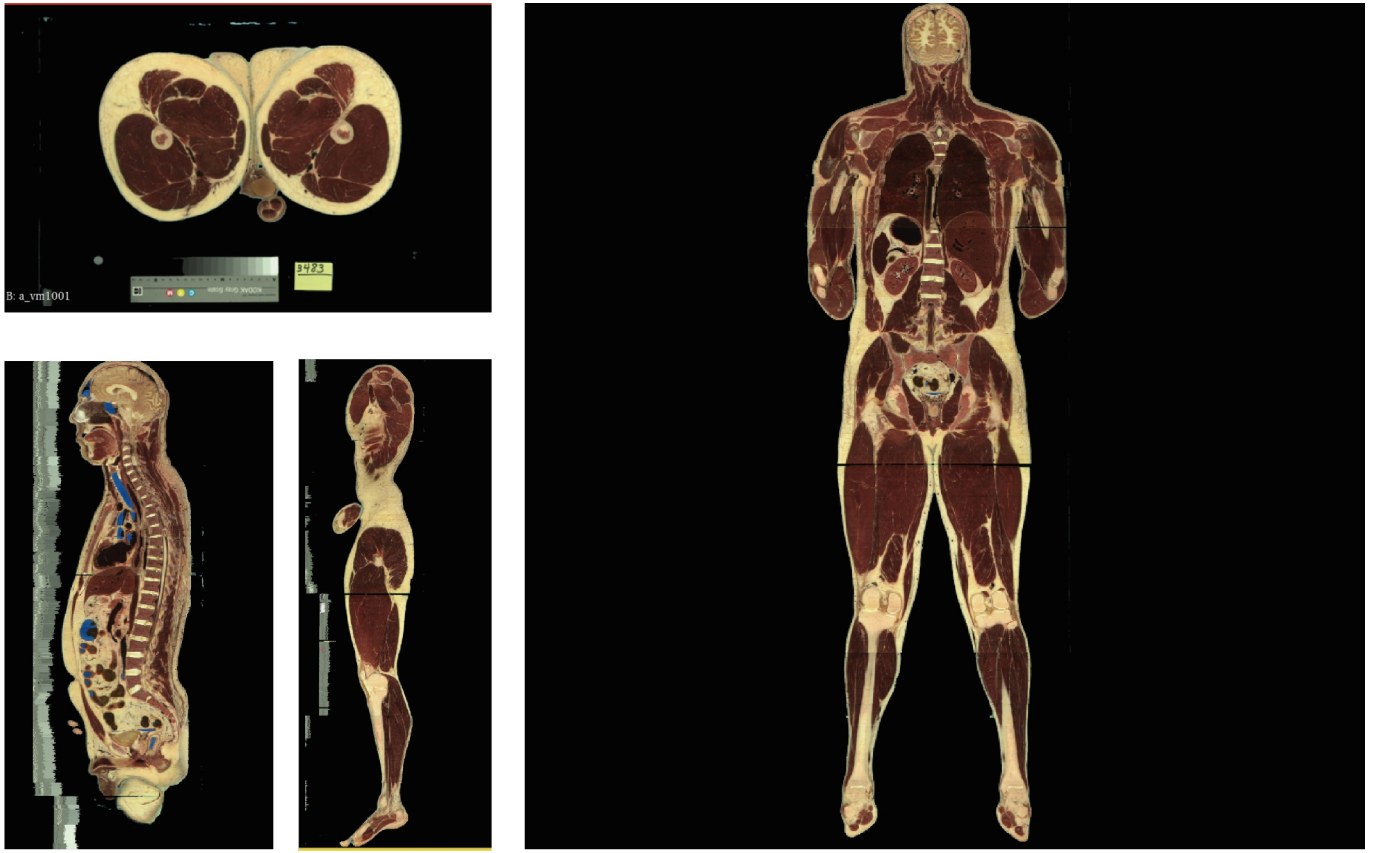


Fig.8-Reconstrução 3D a partir das imagens coloridas sem fundo segmentadas no treinamento

Reconstrução 3D – modelo sólido

Modelo 3D
-Vértices, Faces e Arestas.
reconstruído a partir das imagens segmentadas (VHP) Male.

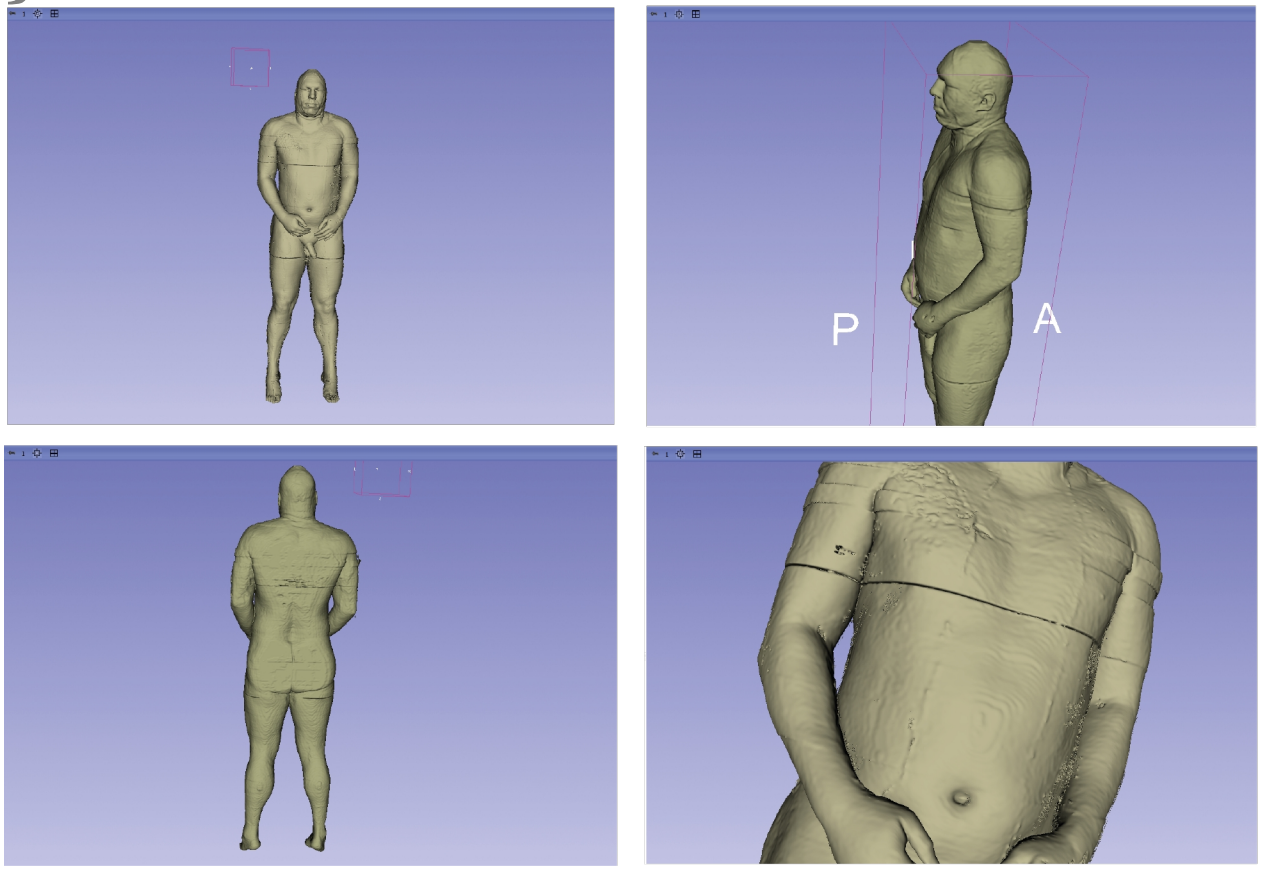


Fig.9 - Reconstrução 3D a partir das imagens coloridas sem fundo segmentadas no treinamento

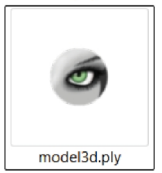
Pós processamento

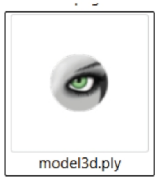


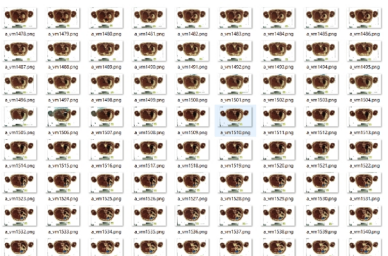
1877 máscaras binárias

3D Slicer

-Threshold
-Islands
-Smoothing
-Create Closed Surface
-Wrap Solidify







1877 imagens sem fundo azul.png

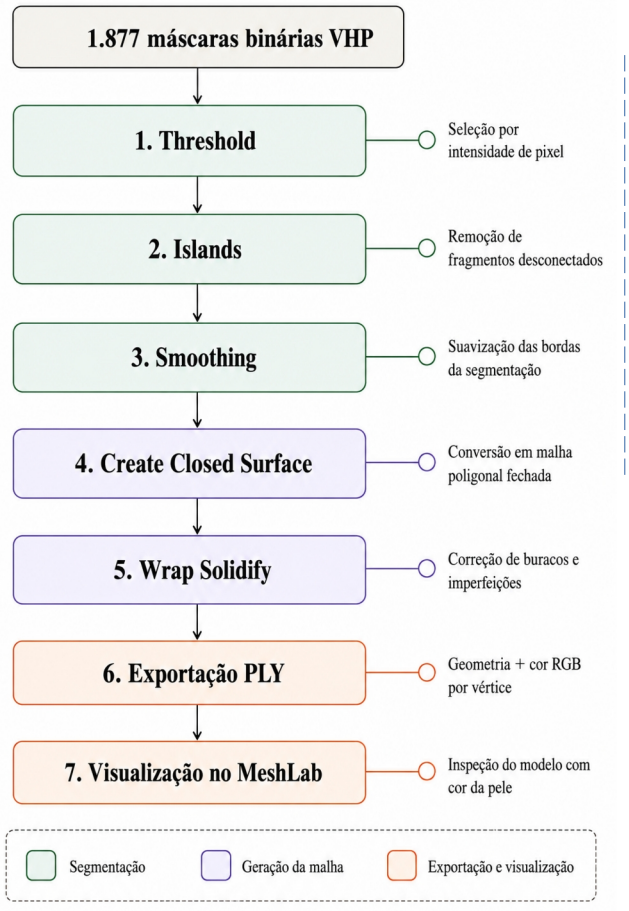
Aplicar_textura_pele.py

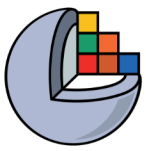
MeshLab

Modelo 3D com textura da pele

Fig.10- Fluxo do Pós Processamento

Texturização do Modelo 3D





3D Slicer

Marching Cubes

Texturização do modelo ply +
RGBA colorização dos vértices

Fig.11-Fluxo da aplicação textura da pele no objeto *.ply* salvo

Pós processamento

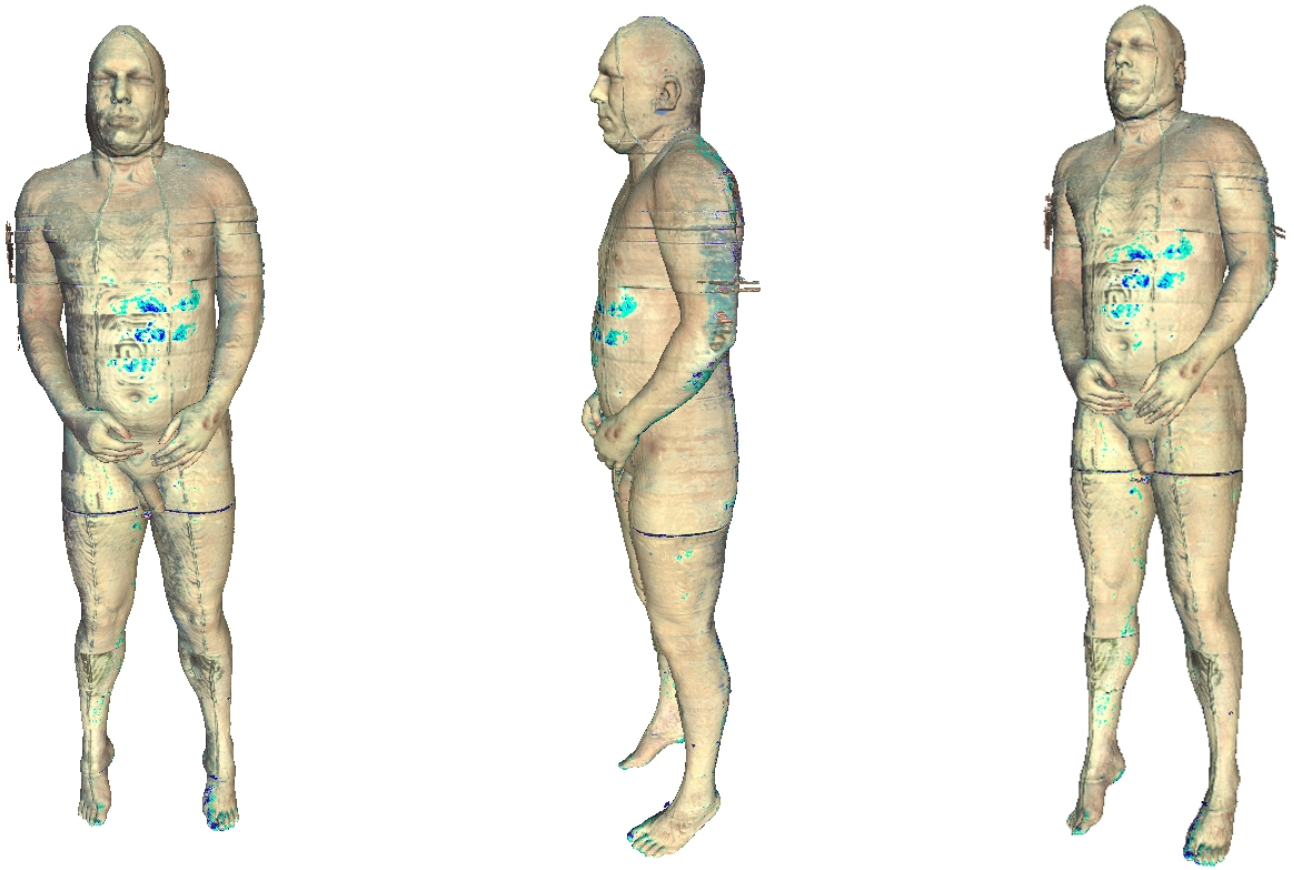


Fig.12 -Modelo 3d em ply com a textura da pele. Detalhe : linhas de costura

Pós processamento



Fig.13 - Detalhe da tatuagem bandeira dos Estados Unidos e uma estrela ombro esquerdo

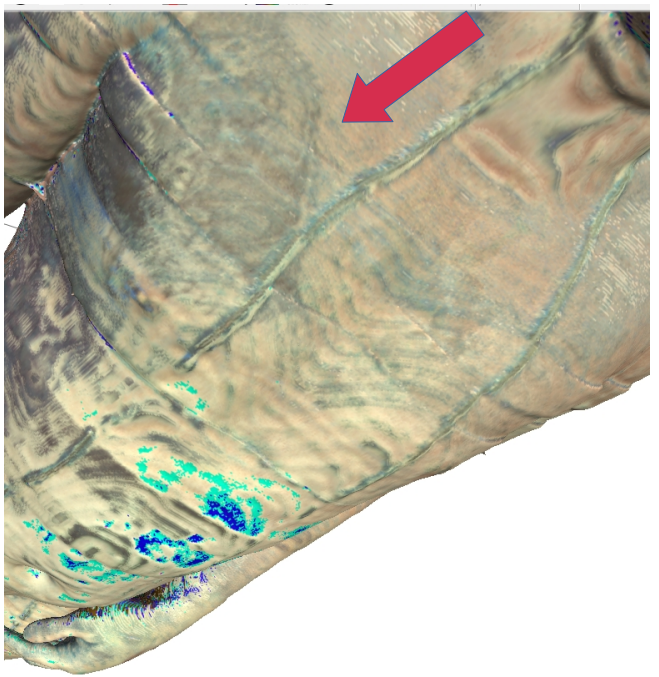


Fig.14 - Detalhe da tatuagem peitoral direito e cortes transversais

Conclusão

- Processamento de um maciço volume de dados – Tempo de processamento
- Gerenciamento de memória - RAM/Disco
- Processamento em lotes.

Perspectiva de trabalhos futuros

- Aprofundar a pesquisa em Ciência de Dados com foco no treinamento de modelos de redes neurais aplicados à segmentação de imagens.
- Comparação entre diferentes variantes da arquitetura U-Net, como a UNet++ e UNet 3D (ZHOU et al., 2018), avaliando o desempenho de cada abordagem em termos de acurácia, eficiência computacional e qualidade da segmentação obtida.

Agradecimentos

OBRIGADA A TODOS!!!

Referências

•NATIONAL LIBRARY OF MEDICINE (NLM). **Visible Human Project.** Disponível em: https://www.nlm.nih.gov/research/visible/visible_human.html. Acesso em: 13 mar. 2026.

•LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. **Deep learning**. Nature, Londres, v. 521, n. 7553, p. 436–444, 2015. DOI: 10.1038/nature14539.

•MITCHELL, T. M. **Machine Learning**. [S. l.]: McGraw-Hill, 1997.

•GONZALEZ, Rafael C.; WOODS, Richard E. **Processamento de imagens digitais**. Edgard Blucher, 2000..

•https://en.wikipedia.org/wiki/Jaccard_index

- https://github.com/LRcyber/Segmentacao_de_imagens_com_redes_neurais