

UNIVERSIDADE ESTADUAL DE SANTA CRUZ

Departamento de Ciências Exatas e Tecnológicas - Curso de Bacharelado em Ciência da Computação

LUCIANA RONCARATI DOS SANTOS

SEGMENTAÇÃO DE IMAGENS RGB COM REDES NEURAIS

Ilhéus - 2026

LUCIANA RONCARATI DOS SANTOS

SEGMENTAÇÃO DE IMAGENS RGB COM REDES NEURAIS

Projeto de Trabalho de Conclusão de Curso submetido à Universidade Estadual de Santa Cruz, como requisito para obtenção do grau de Bacharel em Ciência da Computação. Orientador: César Alberto Bravo Pariente

Ilhéus - 2026

LUCIANA RONCARATI DOS SANTOS

SEGMENTAÇÃO DE IMAGENS RGB COM REDES NEURAIS

Ilhéus, 03/07/2026

_____

Prof. Dr. César Alberto Bravo Pariente. (Orientador)

_____

Profa. Dr(a). Martha Ximena.Torres Delgado (Avaliador)

_____

Prof.Dr. Alvaro Vinicius de Souza Coelho(Avaliador)

Dedico este trabalho à minha mãe e à minha tia, que sempre me inspiraram, apoiaram e incentivaram ao longo de minha trajetória acadêmica. Dedico-o também a mim mesma, pela determinação, disciplina e dedicação que me permitiram superar os desafios e alcançar esta conquista e ao Jack.

AGRADECIMENTOS

Agradeço, primeiramente, à minha mãe e a todos aqueles que contribuíram, direta ou indiretamente, para a realização deste trabalho e que estiveram presentes ao longo desta trajetória, desde o primeiro semestre da graduação até a conclusão do curso.

Agradeço também aos amigos próximos e a todos os professores do Curso de Ciência da Computação da Universidade Estadual de Santa Cruz (UESC), pelo conhecimento compartilhado e pelo aprendizado proporcionado. Em especial, agradeço ao Prof. César Bravo, que possibilitou o desenvolvimento das bases necessárias para a realização deste trabalho; ao Prof. Sérgio Fred, que esteve presente desde a minha primeira graduação, contribuindo significativamente para essa formação acadêmica; à Profa. Marta Magda, pelo constante apoio e incentivo durante todo o curso e aos Professores Alvaro Vinícuis e Martha Ximena que estiveram presente até o último momento do desenvolvimento desse Projeto.

SUMÁRIO

1.INTRODUÇÃO 1

1.1 Contextualização 1

1.2 Organização 4

1.3. Objetivo 5

1.3.1 Objetivo Geral 5

1.3.2 Objetivos Específicos 5

2. JUSTIFICATIVA 6

3.FUNDAMENTAÇÃO TEÓRICA 7

3.1 Imagem Digital 7

3.2 Pixel 7

3.2.1 Relações Básicas Entre Pixel 7

3.2.2 Densidade de uma imagem digital 8

3.3 Espaço de cor RGB 8

3.3.1 RGBA: 9

3.4 Espaço de cor HSV 9

3.5 Segmentação de Imagens 10

3.6 Visão Computacional 10

3.7 Redes Neurais artificiais (RNA's) 11

3.8 CNN's-Redes Neurais Convolucionais 12

3.8.1 U-Net 14

3.9 Visible Human Project (VHP) 14

4. TRABALHOS RELACIONADOS 16

5. METODOLOGIA 19

5.1 Plataforma de Hardware e Software 19

5.2 Aquisição e Preparação dos Dados 19

5.3 Pré Processamento dos Dados 20

5.3.1 Rotulagem 20

5.4 Treinamento do Modelo 22

6. RESULTADOS E DISCUSSÕES 23

6.1 Métricas de Treinamento de Rede Neural 23

6.1.1 Função perda 25

6.1.2 Métricas de Performance 26

6.2 Reconstrução 3d 31

6.2.1 3D Slicer 31

7.PÓS PROCESSAMENTO 33

7.1 MeshLab 33

7.1.1Resultado PLY 35

8. CONCLUSÃO 36

9. PERSPECTIVA DE TRABALHOS FUTUROS 38

REFERÊNCIAS 39

Lista de Figuras

Figura 1 – Matriz imagem Bidimensional……..... 7

Figura 2 – Matriz imagem Bidimensional……... 7

Figura 3 –Vizinhança de 4……... 8

Figura 4 –Vizinhança diagonal…… 8

Figura 5 –Vizinhança de 8……... 8

Figura 6 – Densidade……... 8

Figura 7 – Esquema do cubo de cores RGB normalizado entre 0 e 1. Os pontos ao longo da diagonal principal representam os valores de cinza, do preto na origem ao branco no ponto (1,1,1)……. 9

Figura 8 – Estrutura Perceptron Fonte: wikipedia……... 11

Figura 9 – Estrutura Neurônio Biológico Fonte: Google…….11

Figura 10 – Arquitetura U-Net - Fonte: Nvídia……... 14

Figura 11 – Imagens Originais VHP Fonte: VHP……... 15

Fig. 12 – Máscaras Binárias para treinamento – Unet……..21

Figura 13 – Fórmula Dice…… 23

Figura 14 – Fórmula Binary Cross Entropy (Erro)……..23

Figura 15 – Interseccion over Union / Dice……24

Figura 16 – Comportamento da função de perda (loss) para os conjuntos de treinamento e validação…… 25

Figura. 17 – Evolução das métricas de acurácia, coeficiente Dice e *Intersection over Union (IoU)* para os conjuntos de treinamento e validação ao longo das épocas. 26

Figura 18 – Fluxo de treinamento de aprendizado de máquina rede neural U-net….. 27

Figura 19 – Fluxo da segmentação das imagens com o modelo salvo…… 27

Figura 20 – Resultado da Segmentação 1/2……29

Figura 21 – Resultado da Segmentação 2/2……30

Figura 22 – Imagens Resultado da reconstrução 3D com as imagens sem fundo azul coloridas resultantes da segmentação com a Rede Neural…… 31

Figura 23 – Reconstrução 3d frontal……32

Figura. 24 – Reconstrução 3d lateral……... 32

Figura 26 – Reconstrução 3d posterior…… 32

Figura 26 – Reconstrução 3d torso…….. 32

Figura 27 – Fluxo da importação da textura da pele……34

Figura 28 – Fluxo da importação do modelo com a malha externa em formato.ply... 34

Figura. 29 – Detalhe da tatuagem com a bandeira dos Estados Unidos…….. 35

Figura 30 – Detalhe da tatuagem no ombro direito……. 35

Figura 31 – Detalhe da tatuagem no peitoral direito……... 35

RESUMO

A segmentação de imagens digitais constitui etapa fundamental no processamento de imagens médicas, permitindo o isolamento de estruturas anatômicas de interesse. Este trabalho apresenta um pipeline completo de reconstrução tridimensional a partir do conjunto de dados do *Visible Human Project* (VHP), que disponibiliza fotografias macroscópicas de cortes axiais criogênicos (RGB, 2048×1216 pixels). Para a etapa de segmentação, foi empregado um pipeline de treinamento de uma Rede Neural Convolucional do tipo U-Net treinada a partir do conjunto reduzido de imagens do VHP para a gerar de máscaras binárias de segmentação do conjunto completo. Diferentemente de abordagens clássicas baseadas em quantização de cores ou classificadores lineares (Perceptron e SVM), que operam pixel a pixel sobre o espaço de cor RGB, a U-Net realiza a segmentação semântica considerando o contexto espacial da imagem, resultando em máscaras precisas. A partir dessas máscaras, o trabalho propõe uma etapa de reconstrução volumétrica, da malha tridimensional, além da reconstrução de um modelo oco no 3D Slicer com posterior colorização dos vértices a partir das imagens segmentadas sem fundo azul. O desempenho do modelo de segmentação foi avaliado por meio das métricas de Coeficiente de Dice e *Intersection over Union (IoU)*. Os resultados obtidos demonstram a combinação entre técnicas de Visão Computacional e Aprendizado Profundo para a segmentação e reconstrução tridimensional de estruturas anatômicas a partir de imagens médicas de corte transversal.

Palavras-chave: Segmentação de imagens; Visible Human Project; U-Net; redes neurais convolucionais; pipeline de treinamento; reconstrução 3D; aprendizado profundo; processamento de imagens médicas.

ABSTRACT

Digital image segmentation is a fundamental step in medical image processing, enabling the isolation of anatomical structures of interest. This work presents a complete 3D reconstruction pipeline based on the Visible Human Project (VHP) dataset, which provides macroscopic photographs of cryogenic axial slices (RGB, 2048×1216 pixels). For the segmentation stage, a U-Net Convolutional Neural Network training pipeline was employed; the network was trained on a subset of VHP images to generate binary segmentation masks for the entire dataset. Unlike classical approaches based on color quantization or linear classifiers (Perceptron and SVM)—which operate pixel-by-pixel within the RGB color space—the U-Net performs semantic segmentation by considering the image's spatial context, resulting in precise masks. Based on these masks, the study proposes a volumetric reconstruction stage—generating a 3D mesh and a hollow model in 3D Slicer—followed by vertex colorization using the segmented images (with the blue background removed). The segmentation model's performance was evaluated using the Dice Coefficient and Intersection over Union (IoU) metrics. The results demonstrate the combination of Computer Vision and Deep Learning techniques for the segmentation and 3D reconstruction of anatomical structures from cross-sectional medical images.

Keywords: Image segmentation; Visible Human Project; U-Net; convolutional neural networks; training pipeline; 3D reconstruction; deep learning; medical image processing.

1.INTRODUÇÃO

1.1 Contextualização

O avanço das técnicas de processamento digital de imagens, em conjunto ao desenvolvimento de algoritmos de aprendizado de máquina, vem permitido a automatização de processos, sobretudo no domínio de imagens médicas. Dentre esses processos, destaca-se a segmentação de imagens, etapa fundamental para a extração de elementos de interesse a partir de grandes volumes de dados visuais. Este trabalho propõe a aplicação de técnicas de segmentação baseadas em redes neurais convolucionais (CNN's) para o processamento do conjunto de imagens do *Visible Human Project* (VHP), com o objetivo de viabilizar a reconstrução tridimensional do corpo humano a partir das fatias transversais segmentadas na região de interesse.

A segmentação de imagens digitais é uma etapa fundamental do processamento de imagens, definida como o processo de subdivisão de uma imagem em regiões ou objetos que possuam uma natureza significativa, ou seja, onde podem conter alguma informação ou característica. A segmentação deve ser realizada até o ponto em que os objetos de interesse da aplicação tenham sido isolados. O grau de subdivisão é determinado pelo problema específico (GONZALEZ; WOODS, 2000). Em contextos médicos, essa etapa assume importância essencial, pois permite definir limites entre as estruturas anatômicas em imagens de diagnóstico — importante na estruturação cirúrgica, quantificação de tecidos e monitoramento de patologias dentre outras aplicações.

Segundo Gonzalez e Woods, uma imagem digital é representada como uma matriz bidimensional, onde cada elemento (pixel) possui índices de linha e coluna Figura 1 e 2, que identificam sua posição espacial, e o valor desse elemento identifica o nível de cinza ou a cor. O processo aditivo de cores em modelos cromáticos pode ser interpretado como uma combinação em diferentes proporções, de componentes monocromáticos nas faixas espectrais associadas às sensações de cor vermelha, verde e azul. Essas três cores são responsáveis pela formação das demais sensações cromáticas percebidas pelo olho humano. Dessa forma, vermelho, verde e azul são denominadas cores primárias aditivas, originando o modelo cromático RGB (Red, Green, Blue) (GONZALEZ; WOODS, 2010).

Os sistemas de visão computacional utilizam a tecnologia de inteligência artificial (IA) para simular as capacidades do cérebro humano que são responsáveis pelo reconhecimento e classificação de objetos. Os modelos são treinados para reconhecer dados visuais inserindo grandes quantidades de informações. Os algoritmos de aprendizado de máquina (*machine*

learning -ML) identificam padrões comuns nessas imagens ou vídeos e aplicam esse conhecimento para identificar imagens desconhecidas com precisão (AWS, 2026).

O estudo das Redes Neurais Artificiais (RNAs) veio da observação do sistema de aprendizado biológico. Estas são construídas através de redes complexas de neurônios (MITCHELL, 1997). Posteriormente, a Inteligência Artificial (IA), caminhando junto com a área de Processamento de Imagens, possibilitou o desenvolvimento de sistemas de visão computacional (GONZALEZ; WOODS, 2010). A partir da década de 1970, técnicas de inteligência artificial foram aplicadas na resolução de problemas do mundo real. Com o aumento da complexidade dos problemas e da quantidade de dados disponíveis, surgiu a necessidade de métodos mais avançados, capazes de aprender com experiências anteriores. Esse processo, no qual, algoritmos constroem hipóteses ou funções para resolver determinadas tarefas, é denominado *Machine Learning* ou aprendizado de máquina (FACELI et al., 2011). Problemas de classificação de imagens e reconhecimento de padrões em imagens podem ser considerados mais complexos do ponto de vista computacional e exigem uma arquitetura específica para serem codificados em tempo hábil. A ciência de dados, área de caráter interdisciplinar que se localiza na interface entre a estatística e a ciência da computação, utiliza métodos estatísticos, processos, algoritmos e sistemas para extrair conhecimento e tomar decisões a partir de dados de diversos tipos, sejam eles ruidosos, nebulosos, estruturados ou não estruturados. A ciência de dados avança em função do crescente aumento no volume de dados, funcionando como ferramenta exploratória para análise e determinação de predições.

A Segmentação de imagens, através de treinamento a partir de uma única camada, como no perceptron clássico em comparação ao perceptron Adaline, que se baseia no Erro Quadrático Médio (MSE), evoluindo de uma abordagem baseada em limiares aleatórias, para um aumento na eficiência, fundamentada na minimização do erro acumulado. como no comportamento do modelo um neurônio linear adaptativo (ADALINE), conforme descrito por Widrow e Hoff (1960), garantindo que, mesmo na ausência de uma separação linear ideal no espaço RGB, o algoritmo entregue o hiperplano que melhor separa os dados, dentro do número de iterações permitido — em oposição ao Perceptron de Rosenblatt clássico, que não converge quando os dados não são linearmente separáveis. A otimização de planos de corte via Perceptron/ADALINE (uma abordagem linear e mais simples), quando comparada a redes multicamadas com exemplo a rede neural U-Net para segmentações complexas e não-lineares,

sendo capaz de aprender formas anatômicas detalhadas em vez de apenas separar cores no espaço RGB.

A *U-Net* é uma arquitetura de rede neural convolucional (CNN) projetada especificamente para a segmentação semântica de imagens, com foco inicial em imagens biomédicas. Proposta por Olaf Ronneberger et al.(2015), se tornou o padrão mais ideal para tarefas onde a precisão da localização dos pixels é tão importante quanto a classificação da categoria, desta forma a evolução do treinamento supervisionado em uma rede neural de camada única para multicamadas**,** como por exemplo a rede neural *U-ne*t, que consiste em um caminho de contração e um caminho de expansão, o que lhe confere a arquitetura em forma de U. O caminho de contração consiste em uma rede convolucional típica, formada pela aplicação repetida de camadas de convolução, cada uma seguida por uma função de ativação Unidade Linear Retificada (ReLU) e por uma operação de *pooling*. que é uma operação de subamostragem utilizada em Redes Neurais Convolucionais (CNNs) para reduzir as dimensões espaciais dos mapas de características gerados pelas convoluções. Essa operação divide a entrada em pequenas regiões (*kernels*) e seleciona apenas o maior valor presente em cada uma delas. Durante essa etapa, a resolução espacial da imagem é gradualmente reduzida, enquanto a quantidade de informações relacionadas às características extraídas é aumentada. O caminho de expansão, por sua vez, combina informações espaciais e características por meio de uma sequência de convoluções e operações de concatenação. Nessa etapa, são integradas características de alta resoluções provenientes do caminho de contração, permitindo a recuperação dos detalhes espaciais necessários para a segmentação precisa da imagem.

O treinamento supervisionado realizado no projeto utilizou como métricas de avaliação o Coeficiente Dice (MILLETARI; NAVAB; AHMADI, 2016), a Entropia Cruzada Binária (GOODFELLOW; BENGIO; COURVILLE, 2016) e o Índice de Interseção sobre União — IoU (JACCARD, 1912; LONG; SHELHAMER; DARRELL, 2015),toda elas são métricas padrão utilizadas para treinamento da rede neural convolucional U-Net.

Este trabalho tem como finalidade segmentar um conjunto de imagens que consistem em fatias transversais de um ser humano adulto, pertencentes ao Visible Human Project (VHP), projeto do Instituto Americano de Medicina, mantido pela National Library of Medicine dos Estados Unidos (NATIONAL LIBRARY OF MEDICINE, 2019), reduzindo a quantidade de pixels, a fim de gerar reconstruções do corpo em 3D. O conjunto de dados

utilizado, denominado VHP-Male (masculino), é composto por 1.877 imagens transversais coloridas, com dimensão de 2048 x 1216 pixels e resolução de 72 dpi, totalizando 5,3 GB de armazenamento conforme verificado após do download dos arquivos para o conjunto de imagens .png. que constitui a base necessária para o treinamento supervisionado e a validação do modelo de segmentação RGB proposto.

1.2 Organização

Esse trabalho está organizado da seguinte forma: Introdução, Objetivos, Justificativa Trabalhos Relacionados e Metodologia, Resultados e Discussões, Pós processamento dos dados, Conclusão e Perspectiva de Trabalhos futuros..

1.3 OBJETIVO

1.3.1 Objetivo Geral

Este projeto de Trabalho de Conclusão de Curso tem como objetivo geral apresentar um modelo de reconstrução 3D a partir das imagens segmentadas do *Visible Human Project* (VHP), por meio da combinação de técnicas e métodos de processamento de imagens e de conceitos relacionados às Redes Neurais.

1.3.2 Objetivos Específicos

a) **Pré - processamento** - Criação de Máscaras (Rotulagem)

b) **Treinamento de modelo** de rede neural para efetuar a segmentação das 1877 imagens com 2048x1216 *pixels* e exportação de forma segmentada em área de interesse.

c) **Pós processamento** – Texturização do modelo 3D.

2 JUSTIFICATIVA

A área de processamento digital de imagens (PDI) vem sendo potencializada pela participação crescente de técnicas de visão computacional e modelos de inteligência artificial aplicados na análise de dados visuais complexos (LITJENS et al., 2017). A interdisciplinaridade entre ciência de dados e imagens médicas representa um campo de grande relevância prática, de forma que decisões clínicas dependem cada vez mais de ferramentas computacionais eficientes e capazes de extrair informação precisa a partir de grandes volumes de dados obtidos através das imagens.

A interpretação de imagens médicas, como tomografias computadorizadas (TC) e ressonâncias magnéticas (RM), exige treinamento e habilidades extensivas, pois a segmentação de órgãos e lesões precisa ser realizada camada por camada. A segmentação manual representa uma carga de trabalho extensiva, podendo introduzir viés caso envolva opiniões subjetivas (LITJENS et al., 2017).

A escolha do *Visible Human Project* – Male para o conjunto de dados justifica-se por se tratar de um dos conjuntos de dados anatômicos digitais mais completos disponíveis para pesquisa (SPITZER et al., 1996), composto por 1.877 imagens transversais coloridas, com dimensão de 2048 x 1216 pixels e resolução de 72 dpi, totalizando 5,3 GB de armazenamento. Essas características representam simultaneamente um desafio para algoritmos de segmentação e um ambiente apropriado para a validação de abordagens baseadas em aprendizado supervisionado. Modelos de aprendizado de máquina, como as Redes Neurais Convolucionais (CNNs), são capazes de identificar padrões e classificar imagens a partir do aprendizado de representações hierárquicas de características (LECUN; BENGIO; HINTON, 2015). A utilização de CNNs no VHP objetiva, principalmente, a automatização da segmentação semântica e anatômica dessas imagens. A principal vantagem de empregar redes neurais para segmentar a região de interesse do conjunto de dados VHP é a possibilidade de automatizar a segmentação, treinando a rede a partir de uma pequena amostra do conjunto de dados e extrapolando os parâmetros aprendidos para as demais imagens (RONNEBERGER; FISCHER; BROX, 2015).

3.FUNDAMENTAÇÃO TEÓRICA

3.1 Imagem Digital

Uma imagem digital pode ser definida como uma função bidimensional f(x,y), onde x e y representam coordenadas espaciais de um plano. A intensidade ou nível de cinza da imagem naquele ponto é dada pela amplitude da função f(x) em determinado par de coordenadas (x,y). Uma imagem digital é composta por um número finito de elementos com localização e valores específicos, chamados de elementos pictóricos, elementos de imagem, pels ou pixels, sendo pixel o termo mais utilizado para representar os elementos de uma imagem digital (GONZALEZ; WOODS, 2010).

$$f(x,y) = \begin{bmatrix} f(0,0) & f(0,1) & \dots & f(0,n-1) \\ f(1,0) & f(1,1) & \dots & f(1,n-1) \\ \vdots & & & \\ f(m-1,0) & f(m-1,1) & \dots & f(m-1,n-1) \end{bmatrix}$$

Fig. 1 - Matriz imagem Bidimensional

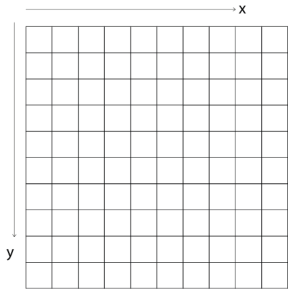


Fig. 2 - Matriz imagem Bidimensional

3.2 Pixel

Segundo Gonzalez e Woods, uma imagem digital é representada como uma matriz bidimensional, onde cada elemento (pixel) possui índices de linha e coluna que identificam sua posição espacial, e o valor desse elemento identifica o nível de cinza ou a cor.

3.2.1Relações Básicas Entre Pixel:

vizinhança de 4 N4(p) é definida por:

Seja p, um pixel nas coordenadas (x, y):

A vizinhança de 4 do pixel p – ou N4 (p) – é composta por seus vizinhos de coordenadas

$$(x + 1, y), (x - 1 , y), (x, y + 1), (x, y-1).$$

A vizinhança diagonal do pixel p – ou ND(p) – é composta por seus vizinhos de coordenadas:

$$(x + 1, y + 1), (x + 1, y - 1), (x -1, y + 1), (x - 1, y - 1).$$

A vizinhança de 8 – ou N8(p) – é composta pelo conjunto de todos os pixels vizinhos, ou seja, N4(p) ∪ ND(p).

3.2.2 Densidade de uma imagem digital

A densidade de uma imagem digital, também denominada resolução espacial, refere-se à quantidade de pixels por unidade de medida conforme Figuras.6,7 e 8, geralmente expressa em pixels por polegada (ppi) ou pontos por polegada (dpi). A relação entre o número de pixels distribuídos em uma mesma área define quanto será a riqueza de detalhes capturados pela imagem (GONZALEZ; WOODS, 2010). A densidade influencia diretamente a qualidade visual e a capacidade de representação fiel de objetos e estruturas presentes na cena imageada, sendo um fator determinante em aplicações de processamento de imagens médicas. No contexto do Visible Human Project (VHP), as imagens foram adquiridas com resolução de 72 dpi e dimensões de 2048 × 1216 pixels, o que representa um compromisso entre o nível de detalhe anatômico e a viabilidade computacional do armazenamento e processamento do conjunto de dados (SPITZER; WHITLOCK, 1998).

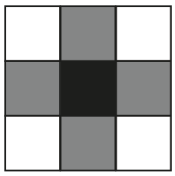


Fig.3-Vizinhança de 4

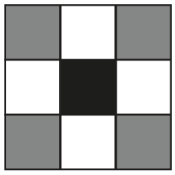


Fig.4-Vizinhança diagonal

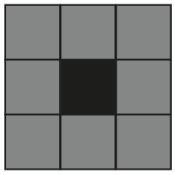


Fig.5-Vizinhança de 8

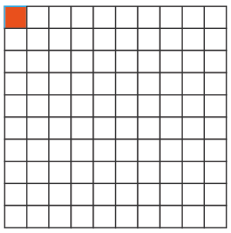
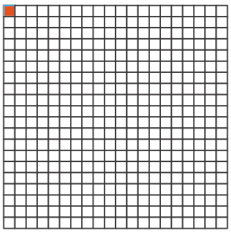
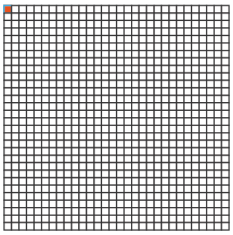


Fig.6-Baixa Densidade





3.3 Espaço de cor RGB

O processo aditivo de cores em modelos cromáticos pode ser interpretado como uma combinação em diferentes proporções, de componentes monocromáticas nas faixas espectrais

associadas às sensações de cor vermelha, verde e azul. Essas três cores são responsáveis pela formação das demais sensações cromáticas percebidas pelo olho humano. Dessa forma, vermelho, verde e azul são denominadas cores primárias aditivas, originando o modelo cromático RGB (Red, Green, Blue) (GONZALEZ; WOODS, 2010). Os valores variam na escala nos tons entre 0 e 255 e a combinação deles em cada escala R, G e B gera as demais cores percebidas.

3.3.1 RGBA:

Sistema de cores formado pelas cores vermelho (red), verde (green), azul (blue) e pelo canal alfa. O sistema permite exibir todas as cores do sistema RGB e a utilização da transparência de imagem, recurso amplamente usado em softwares de edição de imagem com camadas.

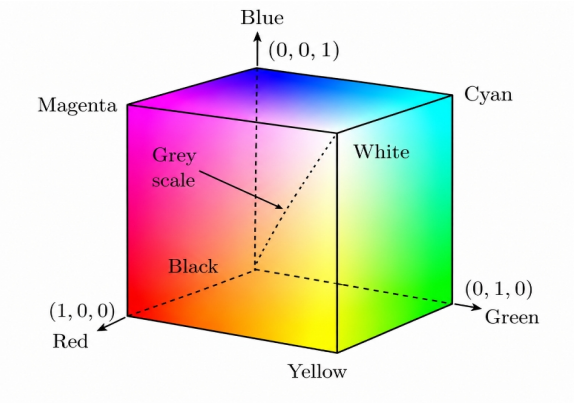


Fig. 7 -Esquema do cubo de cores RGB normalizado entre 0 e 1. Os pontos ao longo da diagonal principal representam os valores de cinza, do preto na origem ao branco no ponto (1,1,1).

3.4 Espaço de cor HSV

HSV (*hue saturation value* ou HSB (*hue, saturation e brightness* — matiz, saturação e brilho, respectivamente). É o sistema de cores definido por: **Matiz (tonalidade):** Verifica o tipo de cor, abrangendo todas as cores do espectro, desde o vermelho até o violeta, mais o magenta. Atinge valores de 0 a 360, mas para algumas aplicações, esse valor é normalizado de 0 a 100%. **Saturação:** Também chamado de "pureza". Quanto menor o valor, mais com tom de cinza aparecerá a imagem. Quanto maior o valor, mais "pura" é a imagem. Atinge valores de 0 a 100%. **Valor (brilho):** Define o brilho da cor. Atinge valores de 0 a 100%.

Descoberto em 1974, por Alvy Ray Smith. É caracterizada por ser uma transformação não-linear do sistema de cores RGB.

3.5 Segmentação de Imagens

A segmentação de imagens é uma técnica da visão computacional (VC) utilizada para particionar uma imagem digital nas regiões mais significativas, com o objetivo de identificar e delimitar objetos, permitindo a realização de tarefas como análise de forma, extração de características e reconhecimento de padrões, por facilitar o processamento de imagens de forma mais rápida e avançada. O processo de segmentação consiste em subdividir as imagens em suas partes ou objetos constituintes. GONZALEZ & WOODS (2000) defendem que o nível até o qual essa divisão deve ser realizada depende muito do problema em questão. Entretanto, a segmentação deve parar quando os objetos de interesse da aplicação tiverem sido isolados. A capacidade de dividir uma imagem em regiões distintas permite extrair informações específicas e realizar análises mais precisas. No entanto, essa tarefa é frequentemente desafiada por fatores como ruído, variações de iluminação e baixa qualidade das imagens, especialmente em contextos onde predominam resoluções médias e baixas.

Considerada como uma etapa fundamental do processamento de imagens, a segmentação de imagens digitais é definida como o processo de subdivisão de uma imagem em regiões ou objetos que possuam uma natureza significativa, ou seja, onde podem conter alguma informação ou característica. Segundo Gonzalez e Woods (2000), o processo de segmentação deve ser realizado até o ponto em que os objetos de interesse da aplicação tenham sido isolados. O grau de subdivisão é determinado pelo problema específico. Em contextos médicos, essa etapa assume importância essencial, pois permite definir limites entre as estruturas anatômicas em imagens de diagnóstico — importante na estruturação cirúrgica, quantificação de tecidos e monitoramento de patologias dentre outras aplicações.

3.6 Visão computacional

O estudo das Redes Neurais Artificiais (RNAs) veio da observação do sistema de aprendizado biológico. Estes, são construídos através de redes complexas de neurônios (MITCHELL, 1997). Posteriormente a Inteligência Artificial (IA) caminhando junto com a área de Processamento de Imagens possibilitou o desenvolvimento de sistemas de visão computacional (GONZALEZ; WOODS, 2010). A partir da década de 1970, técnicas de inteligência artificial foram aplicadas na resolução de problemas do mundo real. Com o aumento da complexidade de problemas e da quantidade de dados disponíveis, surgiu a

necessidade de métodos mais avançados capazes de aprender com experiências anteriores. Esse processo, no qual, algoritmos constroem hipóteses ou funções para resolver determinadas tarefas, é denominado aprendizado de máquina (FACELI et al., 2011).

A inteligência artificial (IA) serve como ferramenta para os sistemas de visão computacional simularem as capacidades do cérebro humano que são responsáveis pelo reconhecimento e classificação de objetos. Os modelos de aprendizado de máquina são treinados para reconhecer dados visuais inserindo grandes quantidades de informações. Os algoritmos de *machine learning* (ML) identificam padrões comuns em imagens ou vídeos e aplicam esse padrão de reconhecimento para identificar imagens desconhecidas com precisão.

Problemas de classificação de imagens e reconhecimento de padrões em imagens podem ser considerados mais complexos do ponto de vista computacional e exigem uma arquitetura específica para serem codificados em tempo hábil. A ciência da dados avança em função do crescente aumento de dados, como ferramenta exploratória para a análise e determinação de predições acerca de grandes conjuntos de dados.

3.7 Redes Neurais artificiais (RNA's)

Um neurônio artificial é uma função matemática concebida como um modelo de um neurônio biológico numa rede neural Fig. 10, basicamente é a unidade elementar de uma rede neural artificial. O neurônio matemático de McCullov e Pitts (1943) possuía pesos fixos e não conseguia aprender sozinho. Já o perceptron proposto por Rosenblatt (1958) Fig.9, algoritmo para aprendizado supervisionado de classificadores binários, permitia o ajuste dos pesos e podia aprender. Um avanço foi fundamentado na minimização do erro acumulado. como no comportamento do modelo um neurônio linear adaptativo (ADALINE) conforme descrito por Widrow e Hoff (1960). Em 1969 Minsky e Papert provaram matematicamente a limitação do modelo Perceptron, pois uma camada só funcionava para dados linearmente separáveis sendo que, para resolver problemas complexos como o da porta XOR, os computadores precisariam de redes com múltiplas camadas de neurônios ou redes neurais multicamadas.

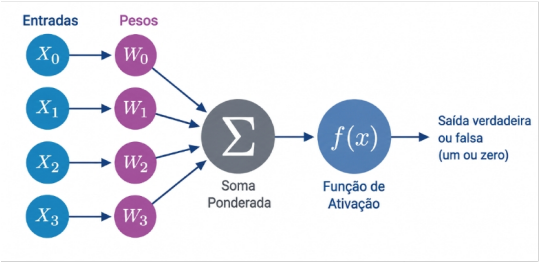


Fig. 8 Perceptron

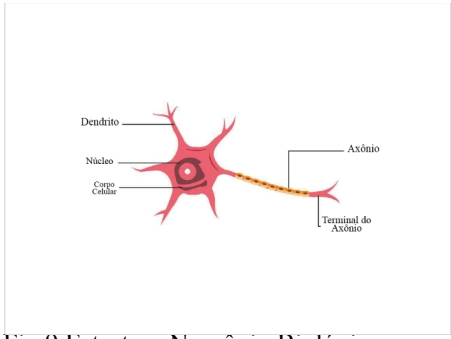


Fig.9 Estrutura Neurônio Biológico

Rumelhart (1986) introduziu o conceito de *Backpropagation* (retropropagação), cujo a lógica consiste em empilhar camadas de neurônios em redes neurais artificiais como uma série de funções matemáticas aninhadas. Durante o treinamento, essas equações interconectadas são aninhadas em outra função: uma "função de perda (*loss*)", que mede a diferença (ou "perda") entre a saída desejada ou para uma determinada entrada e a saída real da rede neural.

A capacidade de aprendizagem é uma das características marcantes das RNAs. Uma rede neural aprende, basicamente, através de um processo iterativo de ajuste de pesos e limiares (bias). Os processos mais avançados de aprendizagem (ou treinamento) são capazes de ajustar não apenas os pesos da rede, mas também sua arquitetura e as funções de ativação dos neurônios é o algoritmo fundamental que permite que as redes neurais artificiais aprendam. Ela calcula a diferença entre o resultado previsto pela rede e o resultado real (erro) e propaga essa informação de volta, ajustando os pesos internos para minimizar o erro nas próximas tentativas. As redes neurais artificiais dos modelos de aprendizado profundo (deep learning) abrangem muitas camadas interconectadas de "neurônios", onde cada uma realiza uma operação matemática. Ao usar o aprendizado de máquina para ajustar a força das conexões entre neurônios individuais em camadas adjacentes, em outras palavras, os pesos e vieses variáveis do modelo, a rede pode ser otimizada para produzir resultados mais precisos.

Lecun em 1998 definiu que tarefas inteligentes, como percepção visual, percepção auditiva e compreensão da linguagem, exigem a construção de boas representações internas do mundo (ou "características"/features), que devem ser invariantes a variações irrelevantes da entrada, preservando ao mesmo tempo as informações relevantes. Uma das principais questões da Aprendizagem de Máquina (*Machine Learning*) é como aprender automaticamente essas boas características.

3.8 CNN's-Redes Neurais Convolucionais

As Redes Neurais Convolucionais (Convolutional Neural Networks – CNNs) constituem uma classe de redes neurais que utilizam a operação de convolução como principal mecanismo de extração de características. De modo geral, seguem o paradigma *feedforward*, no qual os dados percorrem a arquitetura em uma única direção, da entrada para a saída, sem conexões de retorno entre os neurônios. (LECUN; BENGIO; HINTON, 2015).

As CNNs são projetadas para processar dados organizados em múltiplas matrizes. Um exemplo é uma imagem colorida no formato RGB (*Red*, *Green* e *Blue*), composta por três

matrizes bidimensionais, nas quais cada posição representa a intensidade de um pixel em um dos canais de cor. As redes convolucionais exploram a estrutura espacial desses dados por meio da operação de convolução, permitindo a extração automática e hierárquica de características relevantes para tarefas de classificação, detecção e segmentação de imagens (LECUN; BENGIO; HINTON, 2015).

Entre os principais componentes das CNNs destacam-se as conexões locais, os pesos compartilhados e as camadas de *pooling*. As conexões locais permitem que cada neurônio processe apenas uma região específica da entrada, enquanto os pesos compartilhados reduzem significativamente o número de parâmetros da rede. Já a camada de *pooling* é responsável por reduzir a dimensionalidade espacial dos mapas de características produzidos pelas camadas convolucionais, preservando as informações mais relevantes de cada região. Essa redução contribui para diminuir o custo computacional, reduzir o risco de sobreajuste (*overfitting*) e aumentar a robustez da rede a pequenas variações de posição e deformações dos objetos presentes na imagem.

A Camada Convolucional é o coração da rede ela aplica matrizes de pesos (filtros ou *kernels*) sobre a imagem para detectar atributos específicos (como transições de cores, curvas ou contornos).Camada de ReLU (Unidade Linear Retificada): Aplica uma função matemática para inserir não-linearidade na rede, permitindo que ela aprenda padrões complexos sem prejudicar o processo de convolução. Camada de *Pooling* (Subamostragem): Reduz o tamanho espacial e a dimensionalidade dos dados. O método mais comum é o *Max Pooling*, que seleciona o valor mais alto em uma pequena grade de *pixels*. Isso diminui o custo computacional e torna a rede invariante a pequenas translações na imagem.

As redes neurais convolucionais a característica hierárquica das imagens. Nas primeiras camadas, são aprendidas características simples, como bordas e texturas. Em níveis mais profundos, essas características são combinadas para formar padrões mais complexos, como partes de objetos, texturas e, posteriormente, objetos completos. Dessa forma, as CNNs conseguem construir representações cada vez mais abstratas e discriminativas dos dados de entrada (LECUN et al., 2015). O aprendizado profundo tem sido amplamente aplicado à segmentação em imagens médicas. A rede Neural Convolucional U-Net, proposta em 2015, demonstra as vantagens da segmentação precisa de alvos pequenos e sua arquitetura de rede escalável.

3.8.1 Unet

A rede neural U-Net foi desenvolvida por Ronneberger, Fischer e Brox em 2015. Sua arquitetura possui formato em "U", sendo composta por um caminho de contração e um caminho de expansão. O caminho de contração consiste na aplicação repetida de camadas convolucionais, cada uma seguida por uma função de ativação ReLU (*Rectified Linear Unit*) e uma operação de *max pooling*. Durante essa etapa, a resolução espacial é reduzida enquanto as características extraídas são ampliadas. Já o caminho de expansão combina informações espaciais e semânticas por meio de operações de convolução e concatenação com mapas de características de alta resoluções provenientes do caminho de contração, permitindo a localização precisa das estruturas segmentadas (RONNEBERGER; FISCHER; BROX, 2015).

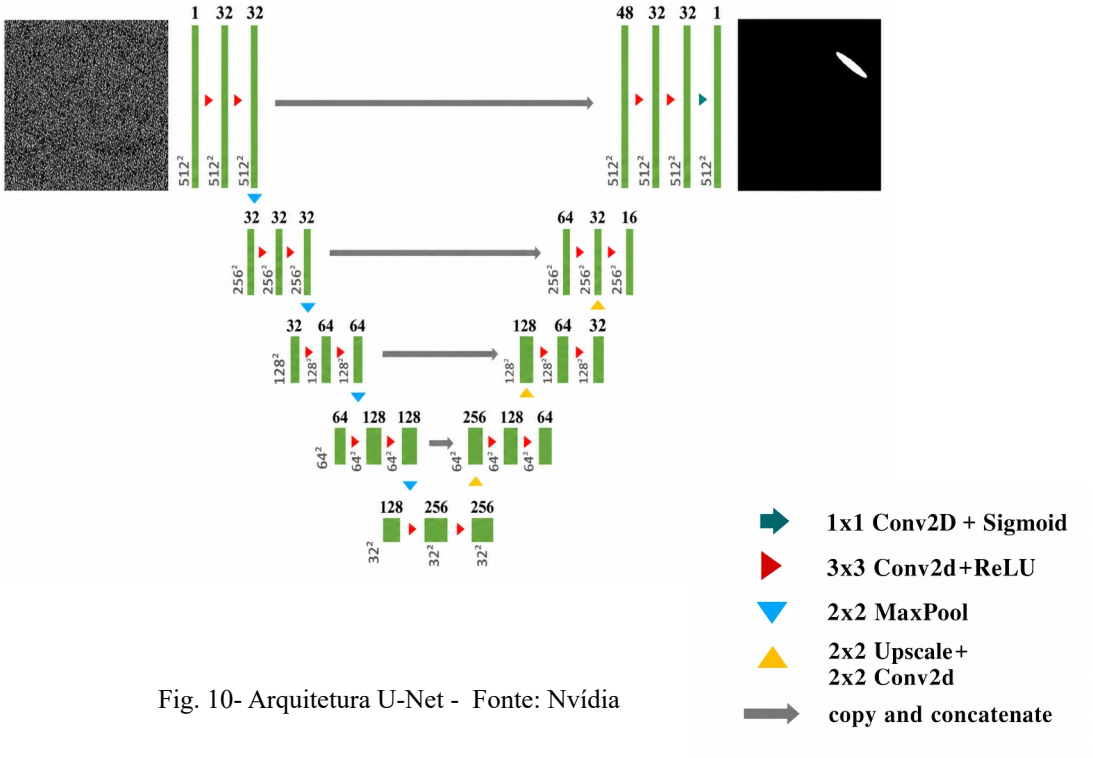
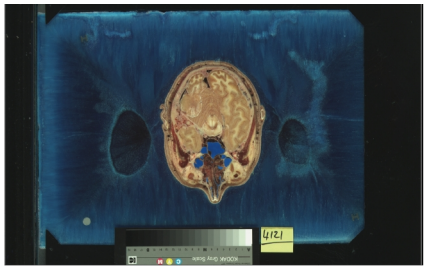


Fig. 10- Arquitetura U-Net - Fonte: Nvídia

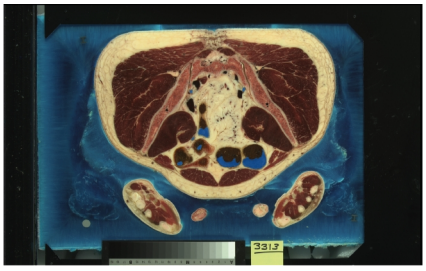
3.9 Visible Human Project VHP

O dataset utilizado é do *Visible Human Project* (VHP), uma iniciativa do NIH (National Institute of Health, EUA), que constitui uma das bases de dados anatômicas digitais mais completas disponíveis para pesquisa. O projeto produziu imagens transversais de corpos humanos inteiros, sendo um masculino e um feminino, obtidas por três modalidades

complementares: Tomografia Computadorizada (CT), Ressonância Magnética (MRI) e fotografias de cortes criogênicos em alta resolução. Para a obtenção das fatias fotográficas, o cadáver foi posicionado em um molde de madeira compensada, envolto em gelatina azul, congelado a aproximadamente -85 °C e fatiado da cabeça aos pés em intervalos de 1 mm. Para cada fatia exposta, foi capturada uma fotografia RGB de 24 bits, com resolução de 2048 x 1216 pixels, totalizando mais de 1878 imagens e aproximadamente 15 gigabytes de dados (SPITZER; WHITLOCK, 1998).



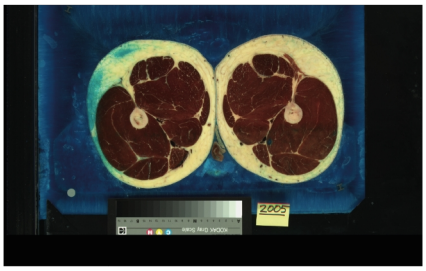
a_vm1121.png



a_vm1818.png



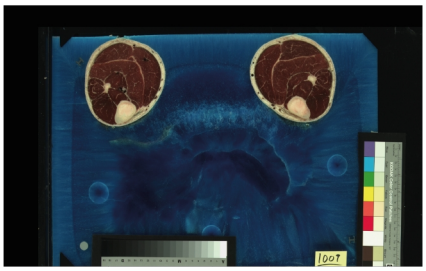
a_vm1291.png



a_vm2021.png



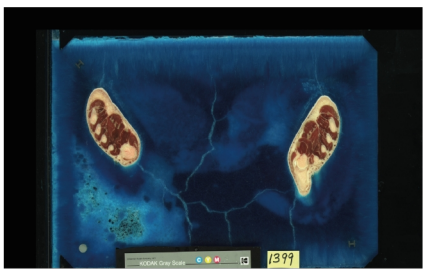
a_vm1493.png



a_vm2441.png



a_vm1609.png



a_vm2831.png

Fig.11-Imagens Originais VHP

4.TRABALHOS RELACIONADOS

No trabalho de Bonfim (2017) é apresentada uma forma de segmentação de imagens baseada no modelo de quantização elaborado em (NASCIMENTO, 2014), onde o modelo proposto realiza o processamento da imagem através de um método não dependente da entrada, desta forma, a escolha da paleta de cores representativa é realizada independente da frequência ou outras características da imagem. A quantização é uma técnica de processamento de imagens que permite a redução do número de cores minimizando a distorção entre a imagem original e a quantizada. A distorção entre essas imagens é calculada pelo Erro Quadrático Médio, do inglês (*Mean Squared Error - MSE*). Desta forma, o uso desta técnica possibilitou não somente a segmentação de regiões como também a redução do espaço de cor das imagens usadas no trabalho.

As perspectivas clássicas de segmentação para imagens em escala de cinza são amplamente documentadas na literatura, consistem em métodos baseados em limiarização (*thresholding*), detecção de bordas e crescimento de regiões e alcançam resultados satisfatórios. Bastos (2020) propôs em seu trabalho um modelo para segmentação de imagens RGB, através da combinação de técnicas e métodos de processamento de imagens e de alguns conceitos derivados das Redes Neurais. Em seu trabalho a utilizou de um perceptron de uma única camada como estratégia para classificação de tons RGB. O treinamento foi realizado de maneira que o perceptron aprendeu sobre determinado tom RGB, no caso do trabalho específico, distinguir tons cianos de não-cianos. Ao final do processamento, o resultado obtido por Bastos (2022), foi de duas imagens no formato PNG|JPG: uma contendo os tons classificados como positivos — correspondentes às regiões de interesse a serem preservadas — e outra contendo os tons classificados como negativos, isto é, associados às regiões consideradas indesejáveis e, portanto, removidas.

Campos (2022) propôs a implementação de um classificador linear estruturado como uma rede neural composta por dois perceptrons, onde o Perceptron 02 recebe como entrada a saída do Perceptron 01. Essa arquitetura teve como objetivo a determinação de um plano de separação ótimo entre duas classes, visando sua aplicação em tarefas de segmentação de imagens digitais. O estudo foi desenvolvido a partir de uma rede com duas camadas, na qual a segunda camada incorpora uma *Support Vector Machine* (SVM) para a identificação e seleção das amostras positivas e negativas utilizadas no processo de treinamento.

Esse trabalho busca apresentar um modelo de reconstrução 3D a partir das imagens do *Visible Human Project* (VHP), por meio da combinação de técnicas e métodos de processamento de imagens e de conceitos relacionados às Redes Neurais, utilizadas para processar dados de entrada na forma de imagem com os canais *Red, Green e Blue* (RGB), composta por três matrizes bidimensionais (2D), onde cada posição da matriz contém a intensidade do pixel para cada um dos canais (LECUN et al., 2015). O Projeto propõe um pipeline completo de reconstrução e segmentação de imagens médicas do VHP utilizando técnicas de Visão Computacional e Aprendizado profundo de máquina.

Um pipeline de treinamento de Machine Learning é a sequência estruturada de etapas usada para transformar dados brutos em um modelo treinado (GOODFELLOW; BENGIO; COURVILLE, 2016): preparação dos dados, pré-processamento, divisão em treino/validação/teste, definição da arquitetura (no caso, a U-Net), treinamento com ajuste de pesos por retropropagação, validação, avaliação por métricas (como Dice e IoU) e, por fim, o salvamento do modelo treinado (.h5) para uso em inferência sobre novos dados.

A diferença fundamental entre a abordagem adotada neste trabalho e os métodos apresentados anteriormente reside na natureza do processo de aprendizado e na capacidade de generalização do modelo empregado. Enquanto os trabalhos de Bonfim (2017), Bastos (2020) e Campos (2022) utilizam estratégias baseadas em quantização de cores, classificadores lineares (perceptron de camada única) ou combinações de perceptrons com SVM — métodos que dependem fortemente de regras pré-definidas, limiares fixos ou hiperplanos de separação linear entre classes de tons —, o presente trabalho emprega uma Rede Neural Convolucional do tipo U-Net, uma arquitetura de aprendizado profundo capaz de aprender automaticamente hierarquias de características espaciais (bordas, texturas e padrões estruturais) diretamente dos *pixels* da imagem, sem a necessidade de extração manual de atributos ou definição prévia de regras de classificação por tonalidade. Diferentemente da quantização proposta por Bonfim (2017), que reduz o espaço de cores da imagem com base em um modelo fixo e não dependente da entrada, ou dos classificadores lineares de Bastos (2020) e Campos (2022), que operam pixel a pixel sobre o espaço de cor RGB para distinguir tons específicos, a U-Net realiza a segmentação semântica considerando o contexto espacial da imagem como um todo, por meio de sua arquitetura encoder-decoder com conexões de salto (*skip connections*), o que permite reconstruir máscaras binárias de segmentação com maior precisão de borda e robustez a variações de iluminação, ruído e heterogeneidade tecidual presentes nas imagens do Visible Human Project. No método aqui especificado, o modelo U-Net (2026-05-

18_Unet_visible_best.h5) é treinado para gerar máscaras binárias de segmentação a partir das 1.877 imagens PNG do VHP, sendo o desempenho do modelo avaliado por meio das métricas de Binary Cross Entropy(erro), Coeficiente de Dice e Intersection over Union (IoU), diferentemente do Erro Quadrático Médio (MSE) utilizado por Bonfim (2017) para mensurar a distorção entre imagem original e quantizada. Além disso, o pipeline proposto não se limita à segmentação: as máscaras geradas pela U-Net alimentam uma etapa subsequente de reconstrução tridimensional.

5. METODOLOGIA

Contextualização do tema e Pesquisa Bibliográfica sobre redes neurais artificiais e suas aplicações na segmentação de imagens: Foi realizada pesquisa bibliográfica e documental relacionada ao tema e algoritmos de processamento de imagens digitais. O projeto foi desenvolvido com pesquisa realizada em LLM para o desenvolvimentismo do pipeline, resolução de problemas relacionados aos processos.

5.1 Plataforma de Hardware e Software

O desenvolvimento deste projeto foi realizado em notebook DELL inspiron com processador Intel Core i5-1235U de 12ª geração, frequência de 1,30 GHz, e 16GB de memória RAM. Para o processamento gráfico e renderização dos modelos tridimensionais foi utilizada a unidade gráfica integrada Intel® Iris® Xe Graphics. Armazenamento com capacidade total de 477 GB-SSD e aplicação VS Code para execução em máquina local e foi utilizado também paralelamente, na tentativa de otimizar o processo, notebook google Colab, que disponibiliza um limite gratuito de 15GB de armazenamento e 12,7GB de memória RAM, GPU Testa T4. Durante o processamento do conjunto total de dados o sistema acusou 98% de RAM utilizada.

5.2 Aquisição e preparação dos dados

Para acesso ao conjunto completo de dados, inicialmente, foi realizado o download automático das imagens anatômicas pertencentes ao projeto *Visible Human Project* (VHP), disponibilizadas pela *U.S. National Library of Medicine*, diretamente na plataforma *Google* Colab. O conjunto das 1877 imagens representa a amostra com dimensões de 2048 x 1026 *pixels* e foram obtidas do repositório oficial com a utilização de requisições HTTP, por meio da biblioteca requests. As imagens são divididas conforme as regiões anatômicas disponibilizadas pelo projeto: *head* (a-vm_1001— a_vm1377), *thorax* (a-vm_1377— a_vm1688), *abdomen* (a-vm_1688— a_vm1997), *pelvis* (a-vm_1997— a_vm2028), *thighs* (a-vm_2028— a_vm2411), *legs* (a-vm_2411— a_vm2878). Foi utilizado um algorítimo em linguagem Python para realizar o download individual de cada imagem no formato .png, essa etapa facilitou automatizar completamente a aquisição do conjunto de dados, reduzindo erros manuais e garantindo padronização na organização das imagens da amostra.

A definição da amostragem para treinamento a partir do conjunto total de 1877 imagens foi feita pela seleção em intervalo de 10 em 10, iniciando em a_vm1001- até

a_vm2878, totalizando 188 imagens. Posteriormente, para uma melhora no aprendizado de máquina, optou-se por um aumento na frequência das imagens utilizando um algorítimo em *Pytho*n que foi executado em máquina local na ferramenta *VScode*. O Algoritmo selecionou mais 120 imagens, caracterizadas por possuir mais bordas/detalhes dentro do conjunto das demais. Para essa etapa também foi utilizado *script* em linguagem Python e execução em máquina local na ferramenta *Vscode.* O filtro utilizado foi detector filtro de Canny é popularmente conhecido, desenvolvido por John F. Canny em 1986. Ele utiliza um algoritmo de múltiplos estágios para identificar transições bruscas de intensidade. Detector de bordas de Canny é indicado devido à sua precisão e baixa taxa de erro, é um algoritmo clássico de visão computacional para detectar bordas em imagens. Segundo Gonzalez e Woods (2018), essa Canny possui maior precisão e menor sensibilidade a ruído em comparação a detectores mais simples, como Sobel e Prewitt. Por atender a critérios rigorosos de boa detecção, boa localização e resposta única, o Canny é amplamente utilizado como referência em tarefas de segmentação de imagens (GONZALEZ; WOODS, 2018).

5.3 Pré-processamento

5.3.1Rotulagem

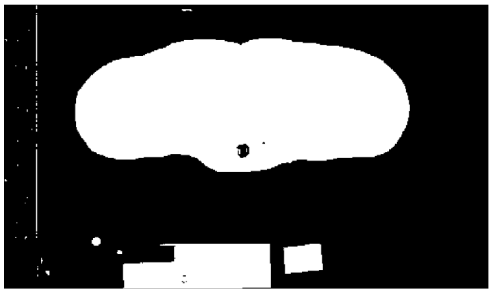
Após a definição da amostragem contendo exatamente 308 imagens foi utilizada função em *python* com conversão HSV, para detecção do fundo azul das imagens e criação das máscaras binárias destinadas para o aprendizado de máquina, onde foi definido aproximadamente 80% para treinamento contendo 246 imagens e 246 máscaras e 62 imagens e 62 máscaras restantes da amostragem correspondendo a 20% destinadas a validação do modelo.



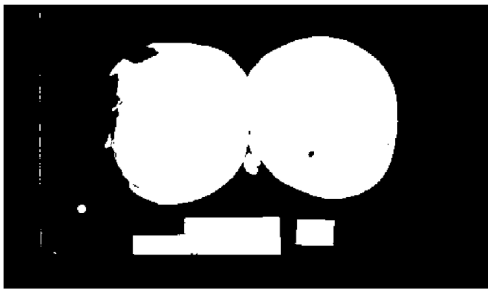
máscara a_vm1121.png



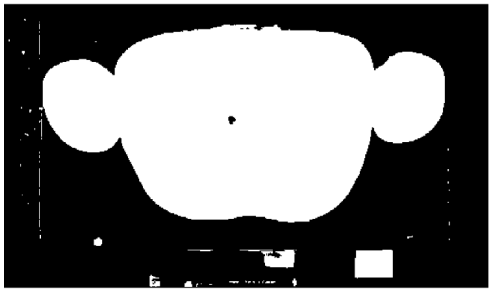
máscara a_vm1818.png



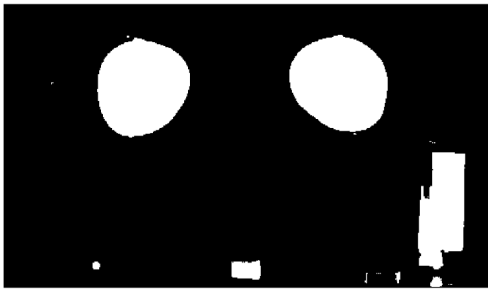
máscara a_vm1291.png



máscara a_vm2021.png



máscara a_vm1493.png



máscara a_vm2441.png



máscara a_vm1609.png



máscara a_vm2831.png

Fig. 12 -Máscaras Binárias para treinamento - Unet

5.4 Treinamento do Modelo

Uma vez definida a amostragem das imagens anatômicas elas foram carregadas no Google Drive em pastas separadas e nomeadas em diretórios: /train e /val, contendo 308 imagens, sendo 246 para treinamento e 46 para validação e suas respectivas máscaras de segmentação binárias onde 1 (um) branco representa o corpo a ser segmentado e 0 (zero) preto representa o fundo em ciano. O objetivo do treinamento é o de ensinar o modelo capaz de segmentar as imagens do corpo humano do fundo azul característico das imagens originais do Visible Human Project (VHP). Após o pré-processamento, as 1877 imagens foi submetida ao modelo de rede neural de arquitetura de multicamadas denominada U-Net, para geração automática das máscaras de segmentação. A saída da rede corresponde a imagens segmentadas com fundo transparente e corpo humano, por meio de um mapa probabilístico contendo valores contínuos entre 0 e 1, representando a probabilidade de cada pixel pertencer à região corporal, enquanto os demais foram classificados como fundo.

O melhor modelo de treinamento no decorrer de 60 épocas foi salvo e treinado com o objetivo de identificar automaticamente a região corporal do fundo azul presente nas imagens anatômicas do banco de dados. O modelo de aprendizado de máquina que apresentou o maior coeficiente dice ($0 < \alpha < 1$) e menor valor da função de perda durante o treinamento das 60 épocas foi salvo.

Os dados do treinamento para o foram salvos no arquivo: **2026-05-18_metricas_treinamento.csv** conforme APÊNDICE A, e o melhor modelo **2026-05-18_Unet_visible_best.h5** o modelo atingiu a melhor taxa de aprendizado na 24 época. O modelo salvo apresentou as melhores métricas e foi armazenado no Google Drive no formato h5, seu carregamento é feito utilizando a biblioteca TensorFlow com a API Keras. O arquivo do notebook foi salvo na nuvem Google Drive e no github -**2026-05-17_Pipeline_ML.pynb.** Todos os modelos produzidos estão disponíveis para o público em geral no link"

https://github.com/LRcyber/Segmentacao_de_imagens_com_redes_neurais

6. RESULTADOS E DISCUSSÕES

6.1 Métricas de Treinamento de Rede Neural:

As métricas utilizadas para salvamento do melhor modelo de treinamento supervisionado são: **Coeficiente Dice** ou índice de Sørensen-Dice, ou "coeficiente de similaridade", métrica estatística usada para medir a similaridade ou a sobreposição entre dois conjuntos de dados ou duas amostras. Ele varia entre 0 (sem sobreposição) e 1 (combinação ou sobreposição idêntica) **Entropia Cruzada Binária** (Binary Cross Entropy) utilizada em problemas de classificação binária e segmentação semântica, medindo a divergência entre a distribuição de probabilidade prevista pela rede e o rótulo real de cada amostra ou pixel (GOODFELLOW; BENGIO; COURVILLE, 2016), **Intersection over Union – IoU** ou Índice de Jaccard, é uma métrica que quantifica a sobreposição entre a máscara de segmentação predita pelo modelo e a máscara de referência (*ground truth*), calculada pela razão entre a área de interseção e a área de união dos dois conjuntos, variando de 0 (nenhuma sobreposição) a 1 (sobreposição perfeita) (JACCARD, 1912)

Fórmula baseada na matriz de confusão.

$$Dice = \frac{2 \times TP}{(2 \times TP) + FP + FN}$$

Fig. 13 Fórmula Dice

TP= Verdadeiro Positivo

FP= Falso Positivo (considera o ruido)

FN= Falso Negativo(ignora pele)

$$L_{\text{BCE}} = -\frac{1}{N}\sum_{i=1}^{N}[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)]$$

Fig.14 – Fórmula Binary Cross Entropy (Erro)

N = número total de pixels;

yi = valor real (ground truth) do pixel i, sendo 0 ou 1;

pi = probabilidade prevista pela U-Net para o pixel i pertencer ao objeto;

LBCE = valor da perda (erro).

$$Dice = \frac{2 \cdot IoU}{IoU + 1}$$

Fig.15 – Interseccion over Union / Dice

Treinamento

O treinamento foi realizado em plataforma Google Colab e foi configurado para 60 épocas, porém o mecanismo (parada) *Early Stopping* interrompeu o processo na época 39 devido a taxa de aprendizado se manter inalterada e à ausência de melhoria do coeficiente Dice de validação durante 15 épocas consecutivas. O melhor desempenho foi obtido na época 24, com Dice de validação de 0,9796 e IoU de validação de 0,9601, sendo esse modelo automaticamente restaurado e armazenado para uso posterior.

- **Época:** Número da iteração completa sobre o conjunto de treinamento.
- **Acurácia:** Percentual de pixels classificados corretamente.
- **Coef. Dice:** Sobreposição entre máscara prevista e real.
- **IoU Score:** Interseção sobre união entre predição e verdade.
- **Loss:** (Perda): Erro
- **Val. Acurácia:** Acurácia no conjunto de validação
- **Val. Coef. Dice:** Dice no conjunto de validação
- **Val. IoU Score:** IoU no conjunto de validação
- **Val. Loss:** Perda no conjunto de validação
- **Tx. Aprendizado:**. (LR): Taxa de aprendizado do otimizador

O melhor modelo foi salvo na 24º época formato h5 no google Drive com as respectivas métricas de treinamento.

Val Accuracy = 0.9877

Val Dice = 0.9796

Val IoU = 0.9601

Val Loss = 0.0251

6.1.1 Função perda

O gráfico de métricas de desempenho mostra a evolução temporal durante 39 épocas de processamento. Observa-se que, a partir da 5ª época, o algoritmo apresenta uma curva de aprendizado acentuada, superando a instabilidade inicial e convergindo para um patamar de estabilidade de alto desempenho.

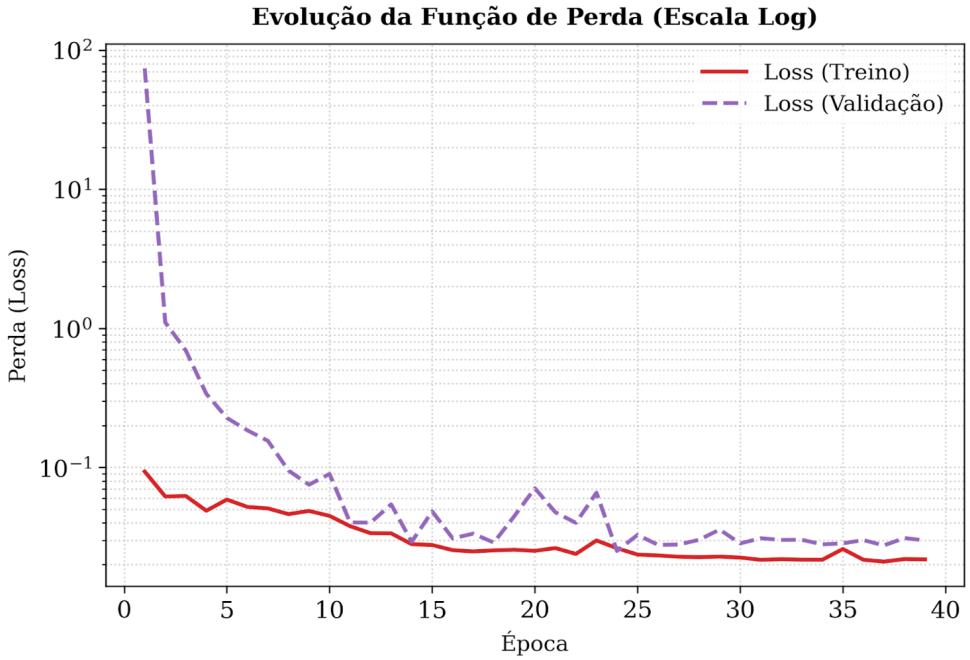


Fig. 16 – Comportamento da função de perda (loss) para os conjuntos de treinamento e validação.

O gráfico ilustra a minimização da função de perda (loss) ao longo do processo de otimização dos pesos sinápticos da rede neural, refletindo a redução do erro sistemático do sistema.

6.1.2 Métricas de Performance

Acurácia: métrica que quantifica a taxa global de acertos de classificação, atingiu estabilidade com valores superiores a 98% no conjunto de treinamento e 98,6% no conjunto de validação. a proximidade entre ambas as curvas atesta a homogeneidade do aprendizado.

Coeficiente Dice: Sendo um índice rigoroso para a avaliação de similaridade em segmentações, os valores obtidos consolidaram-se na faixa entre 97% e 98%. O resultado comprova a alta precisão do modelo na delimitação e concordância espacial das regiões de interesse em relação ao gabarito

Métrica IoU (Intersection over Union): O IoU convergiu para patamares próximos a 95% no conjunto de validação. Esse comportamento ratifica a robustez topológica das predições efetuadas.

Função de Perda no Treinamento: Exibe um decaimento desde o ciclo inicial, o que evidencia que o algoritmo de otimização e a taxa de aprendizado adotada (*learning rate*) foram adequados para guiar o modelo em direção ao mínimo global.

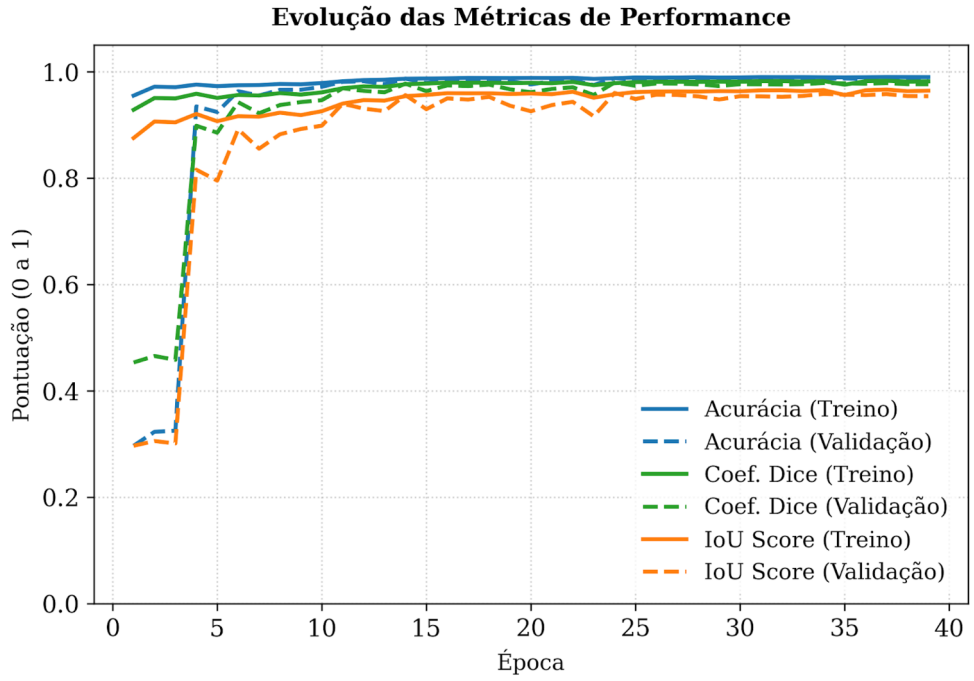


Fig. 17 – Evolução das métricas de acurácia, coeficiente Dice e Intersection over Union (IoU) para os conjuntos de treinamento e validação ao longo das épocas.

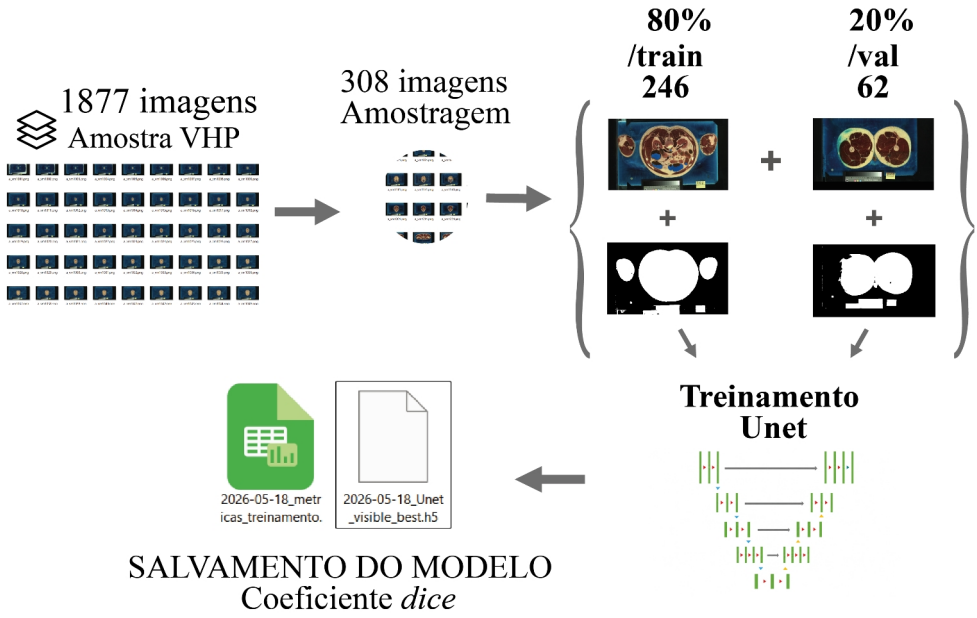


Fig. 18 – Fluxo de treinamento de aprendizado de máquina rede neural U-net

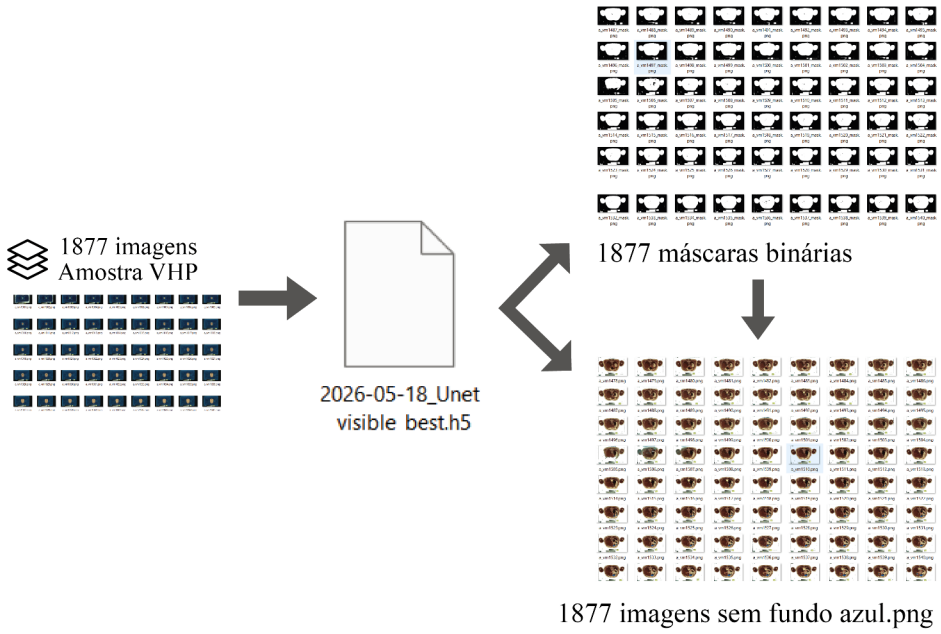


Fig. 19 fluxo da segmentação das imagens com o modelo de treinamento salvo

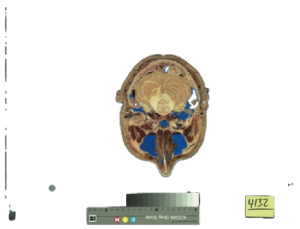
O melhor modelo salvo no formato h5 foi utilizado no pipeline para segmentação do conjunto completo de dados contendo 1877 imagens no ambiente da plataforma do Google *Colab* e Google Drive. Após o carregamento de todas as imagens compactadas no Colab as imagens foram carregadas e segmentadas gerando como saída 1877 imagens no formato PNG contendo canal alfa (RGBA- transparência). O procedimento consistiu em criar um canal alfa a partir da máscara binária, concatenar esse canal à imagem RGB e salvar o resultado no ambiente de execução do *Colab*. Como resultado, o fundo azul é removido e apenas o corpo permanece visível, com fundo transparente em todas as imagens conforme figuras 18 e 19. As imagens e as máscaras binárias resultantes do treinamento foram processadas o *Colab* e salvas em máquina local.

O formato h5 constitui o padrão adotado para a persistência de modelos de Aprendizado Profundo, sendo amplamente utilizado por bibliotecas como *Keras* e *TensorFlow.* Considerando que o processo de treinamento de uma rede neural frequentemente se estende por várias horas, o armazenamento periódico do progresso obtido é essencial para evitar a perda de dados em decorrência de interrupções. O arquivo .h5 armazena, de forma integrada, a arquitetura completa da rede — incluindo a disposição e a conectividade entre as camadas —, os pesos e vieses (bias) que representam o conhecimento adquirido pelo modelo durante o treinamento, bem como as configurações do otimizador, possibilitando que o processo de treinamento seja retomado exatamente a partir do ponto em que foi interrompido.

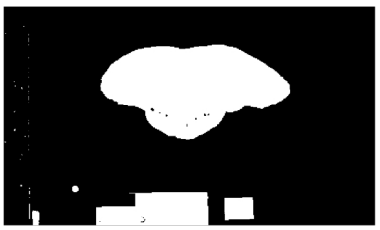
Conforme figura 20 e 21 o modelo apresentou boa capacidade de generalização, segmentando corretamente o contorno corporal e diferenciando-o do fundo azul, mesmo com variações na forma e na distribuição interna dos tecidos entre as fatias, além de identificar corretamente estruturas anatômicas separadas do corpo principal (como braços seccionados). Como limitação, observou-se a presença de pequenos falsos positivos nas máscaras, associados à etiqueta numérica e à escala de cinza padrão presentes no canto das imagens originais. Ainda assim, a imagem segmentada final preservou de forma satisfatória a fidelidade cromática das estruturas internas, condição necessária para as etapas subsequentes de reconstrução tridimensional e texturização do modelo.

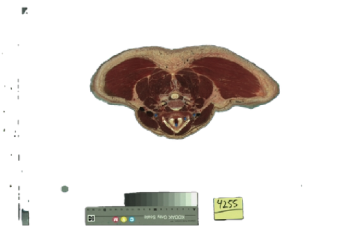

a_vm1132.png

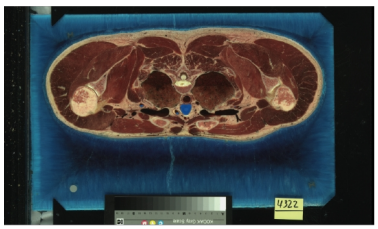

a_vm1132.png- Máscara


a_vm1132 .png- Imagem Segmentada

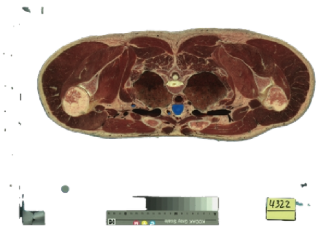

a_vm1255.png


a_vm1255.png- Máscara

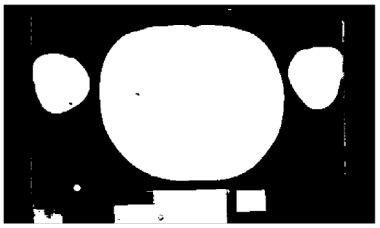

a_vm1255.png - Imagem segmentada

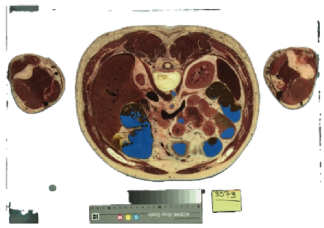

a_vm1322.png


a_vm1132 .png- Máscara


a_vm1132.png - Imagem segmentada


a_vm1578.png


a_vm1578.png - Máscara


a_vm1578.png - Imagem segmentada


a_vm1787.png


a_vm1787.png - Máscara

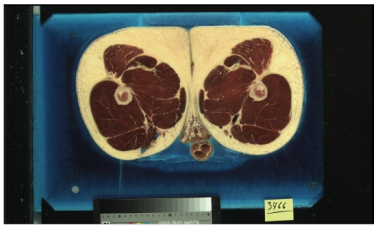

a_vm1787.png - Imagem segmentada


a_vm1899.png

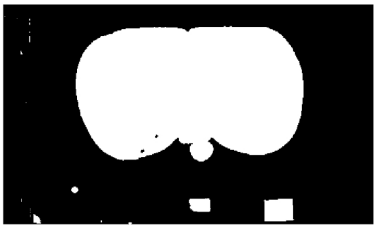

a_vm1899.png- Máscara


a_vm1899.png- Imagem segmentada

Fig.20 Resultado da Segmentação 1/2



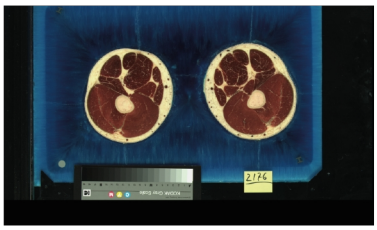
a_vm1971.png



a_vm1971.png - Máscara



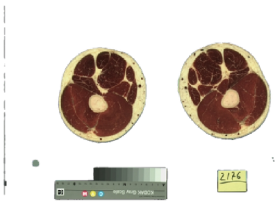
a_vm1971.png - Imagem Segmentada



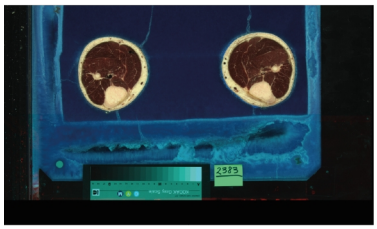
a_vm2192.png



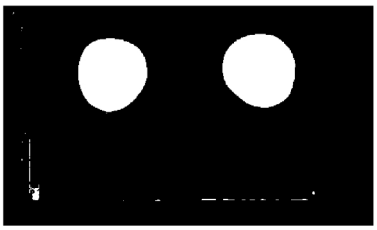
a_vm2192.png - Máscara



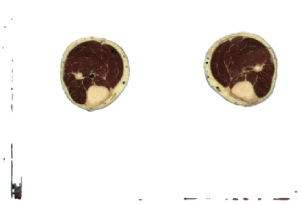
a_vm2192.png - Imagem Segmentada



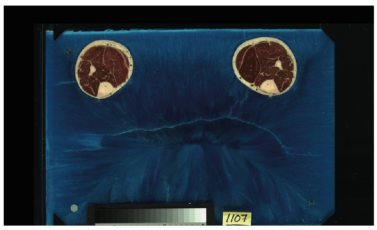
a_vm2399.png



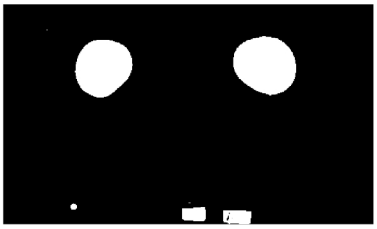
a_vm2399.png - Máscara



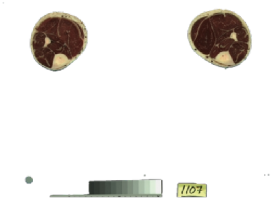
a_vm2399.png - Imagem Segmentada



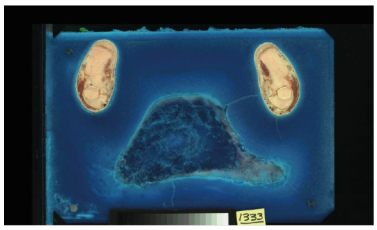
a_vm2539.png



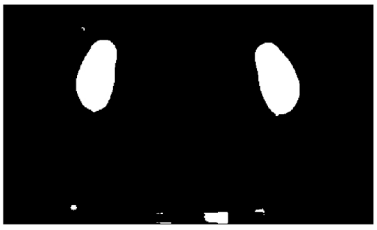
a_vm2539.png - Máscara



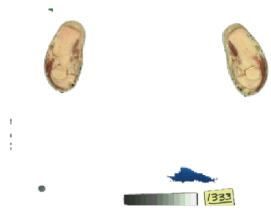
a_vm2539.png - Imagem Segmentada



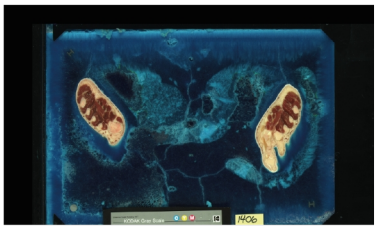
a_vm2765.png



a_vm2765.png - Máscara



a_vm2765.png - Imagem Segmentada



a_vm2838.png



a_vm2838.png - Máscara



a_vm2838.png - Imagem Segmentada

Fig.21 Resultado da Segmentação 2/2

6.2 Reconstrução 3d

6.2.1 3D Slicer

Após segmentação com a extração do fundo azul(ciano) das imagens, o conjunto de dados sofreu uma redução de tamanho de 5,3 GB para 2,24 GB de armazenamento em disco. As imagens segmentadas foram utilizadas para reconstrução do volume 3D com o uso da ferramenta de código aberto 3D slicer..

No ambiente do 3D Slicer, as foram carregadas e, em seguida, ajustadas para o espaçamento entre fatias de 0,33 mm × 0,33 mm × 1,00 mm, conforme as especificações do *Visible Human Project* (VHP), porém ao utilizar o fator = 1 que corresponde ao tamanho original a máquina acusa estouro de memória RAM e a aplicação é interrompida, apenas o fator = 0.25 de redução possibilitou a reconstrução adequada do volume tridimensional.

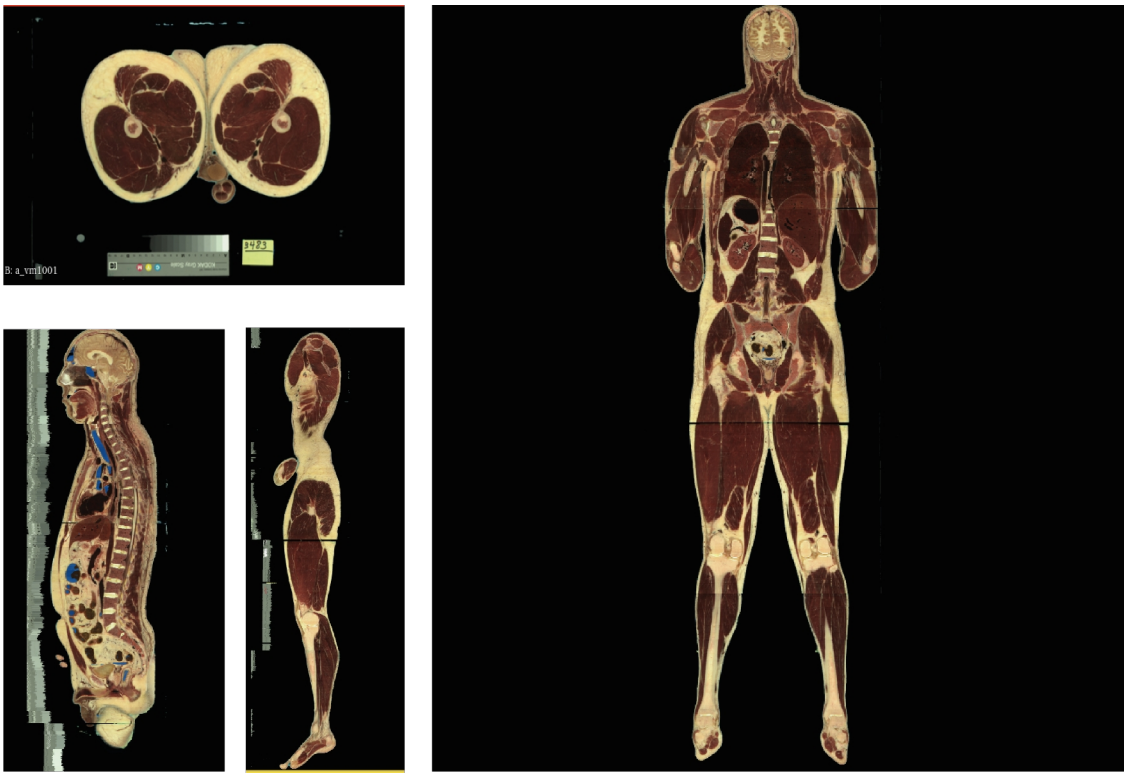


Fig.22 Imagens Resultado da reconstrução 3D com as imagens sem fundo azul coloridas resultantes da segmentação com a Rede Neural

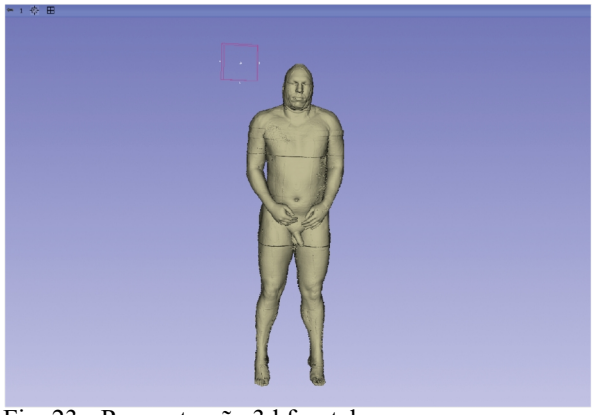


Fig. 23 - Reconstrução 3d frontal

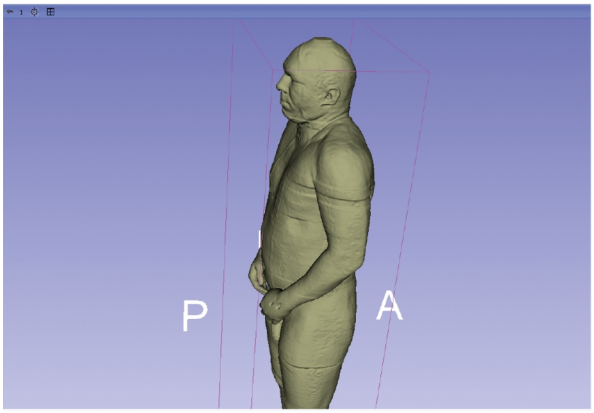


Fig. 24 Reconstrução 3d lateral

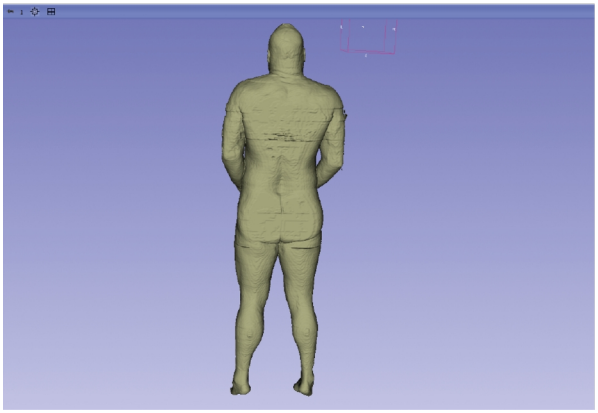


Fig. 25 Reconstrução 3d posterior

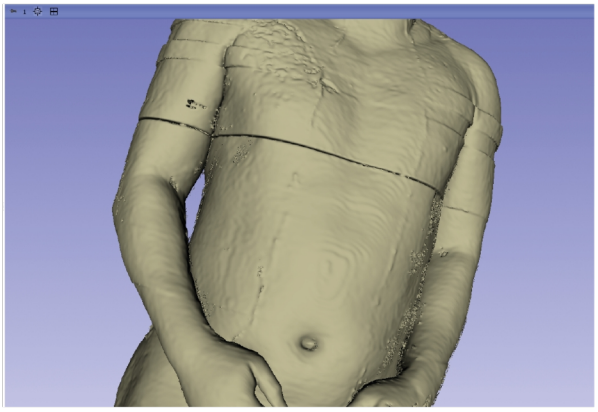


Fig. 26 Reconstrução 3d torso

7.PÓS PROCESSAMENTO

O modelo gerado a partir das imagens coloridas, utilizando o fator de redução 0,25 em relação às imagens originais sem fundo azul, produziu um total de vértices na escala de 10^6, tornando o processamento computacional para extração de características, como a cor da pele inviável dentro das limitações de hardware disponíveis. Para permitir a criação do modelo com textura da pele, foi necessária a recriação do modelo 3D. Desta vez, foram utilizadas as máscaras binárias resultantes da segmentação pela rede neural — onde corpo corresponde ao valor 1 e fundo ao valor 0 — para a construção do modelo oco. A partir do modelo exportado no formato .ply, foram processadas as 1877 imagens sem fundo, possibilitando a geração da textura da pele sobre a superfície do modelo com o conjunto completo de dados, simplificando o volume de informações para análise dos aspectos externos dentro das limitações de hardware disponíveis. Desse modo, foi possível visualizar detalhes como a tatuagem no ombro esquerdo com a bandeira dos Estados Unidos e no peitoral direito, aparentemente um tribal em tom escuro.

7.1 MeshLab

O fluxo é composto por *Threshold → Islands → Smoothing → Create Closed Surface → Wrap Solidify → Exportação PLY*. Posteriormente o script *aplicar_textura_pele.py* realiza a etapa de texturização do modelo 3D reconstruído a partir das fatias coloridas sem fundo. O processo recebe como entrada o arquivo model3d.ply, que contém a malha tridimensional com 2.267.910 vértices e 4.535.680 faces ,geradas pela etapa de *Marching Cubes,* e as imagens RGBA sem fundo.

O arquivo PLY foi posteriormente importado para o *MeshLab.*. A preservação das informações de cor permitiu observar detalhes superficiais da pele presentes nas imagens originais do VHP. Entre os elementos identificados destacam-se características anatômicas externas, variações naturais de coloração e tatuagens presentes no indivíduo do conjunto de dados. Durante a visualização da malha foi possível identificar claramente a tatuagem da bandeira dos Estados Unidos e uma tatuagem estilo tribal, demonstrando que o processo de reconstrução conseguiu preservar detalhes visuais relevantes da superfície corporal. A presença desses elementos evidencia a fidelidade do método adotado e a capacidade da reconstrução de manter informações anatômicas e cromáticas provenientes do conjunto de imagens original.

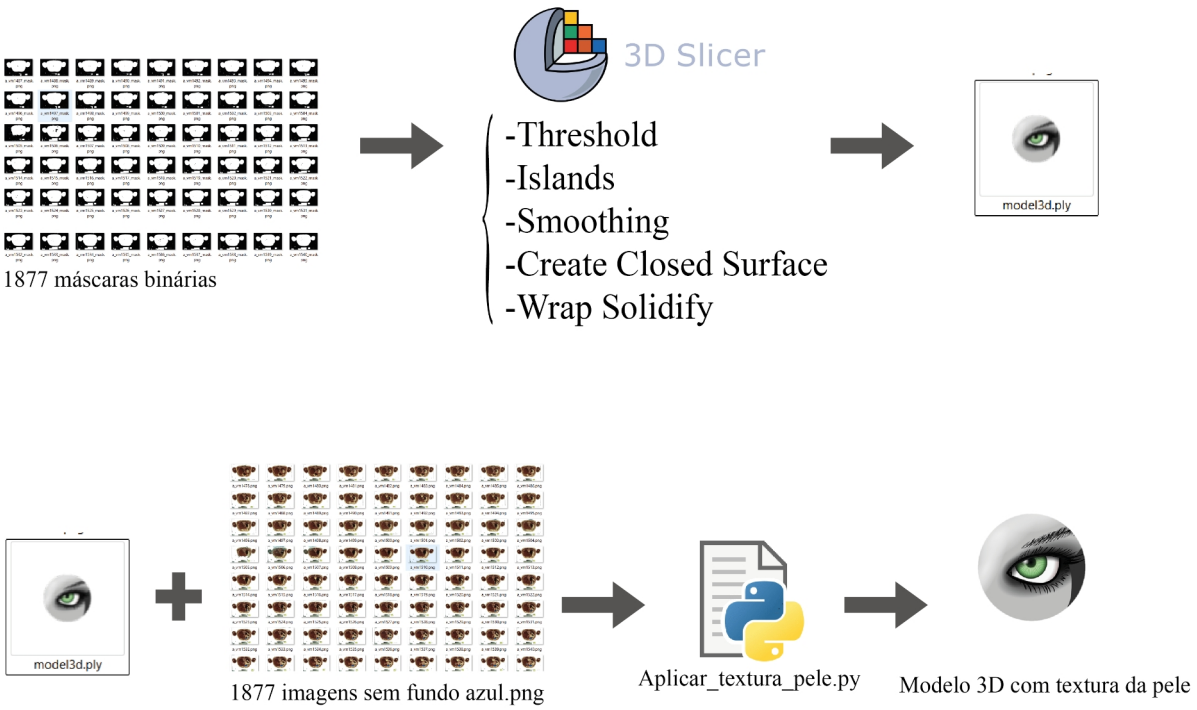


Fig. 27 Fluxo da importação da textura da pele

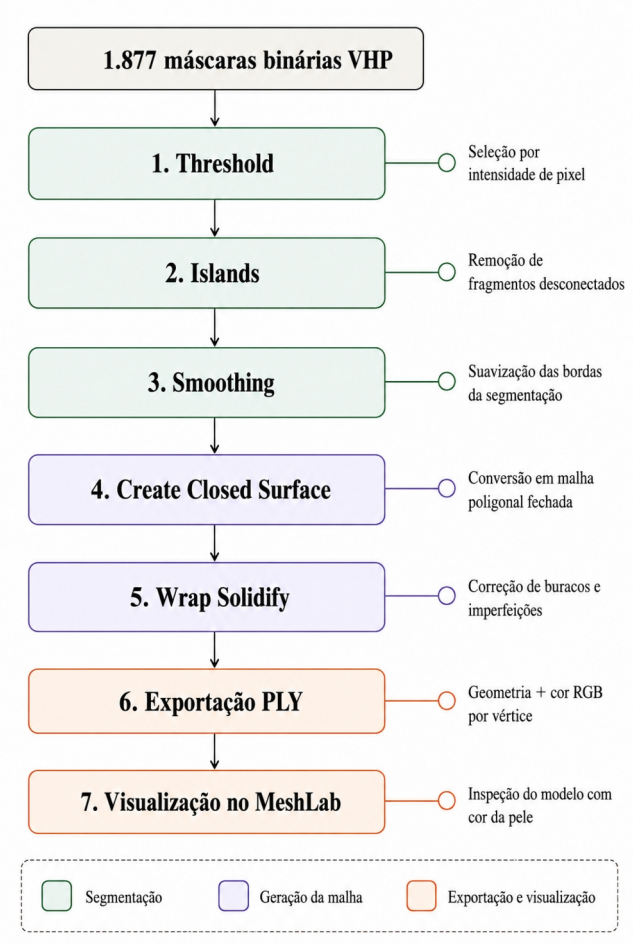


Fig. 28 Fluxo da importação do modelo com a malha externa em formato.ply

7.1.1Resultado PLY+ textura

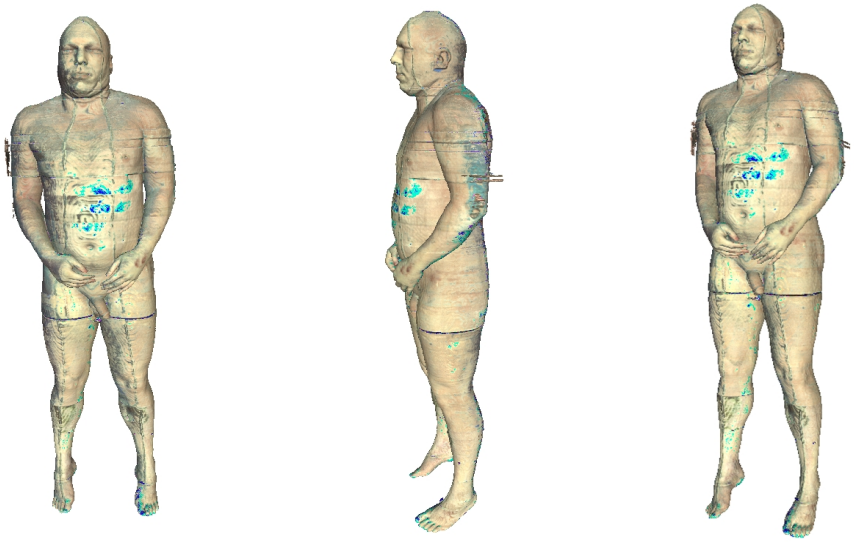


Fig. 29 Modelo 3d em ply com a textura da pele



Fig. 30 Detalhe da tatuagem com a bandeira dos Estados Unidos

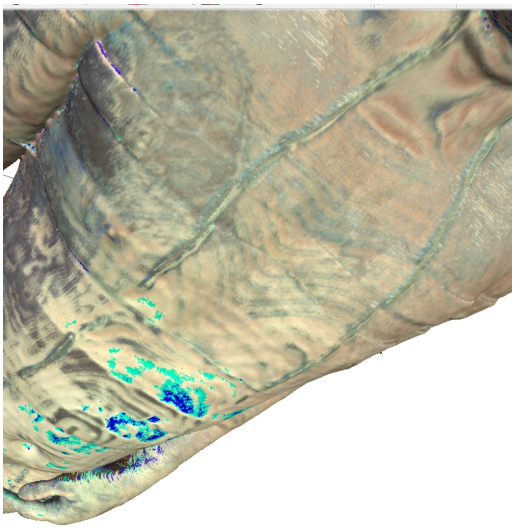


Fig. 31 Detalhe da tatuagem no peitoral direito

8. CONCLUSÃO

Os trabalhos correlatos, embora tenham avançado até a etapa de reconstrução 3D, precisaram reduzir a quantidade de imagens utilizadas do VHP, o que resultou em modelos finais com menos detalhes. Já no presente trabalho, o conjunto completo das 1.877 imagens é utilizado, sem descartar nenhuma fatia do VHP. Para tornar isso viável computacionalmente, foi aplicado um fator de redução de escala (FATOR=0.25) sobre a resolução de cada imagem individualmente, e não sobre a quantidade de imagens do conjunto de dados. Ou seja, todas as fatias continuam sendo processadas e incorporadas à reconstrução, apenas com menor resolução por imagem, o que reduz o custo de memória e processamento sem eliminar informações estruturais do conjunto como um todo. Essa diferença é importante: enquanto os trabalhos anteriores reduziram o dataset com menos imagens da amostra, este trabalho reduziu apenas a resolução (mesma quantidade de imagens, em tamanho menor), preservando a continuidade anatômica entre as fatias e resultando em um modelo 3D final mais completo e detalhado.

Além disso, é importante destacar uma decisão no método adotado para viabilizar computacionalmente a etapa de reconstrução: a utilização de máscaras binárias de segmentação, em vez das imagens coloridas segmentadas (sem o fundo azul). Isso porque, ao aplicar o *Marching Cubes* diretamente sobre as imagens coloridas segmentadas, o algoritmo passava a gerar também vértices internos, referentes à segmentação de órgãos internos presentes nas fatias, o que resultava em um estouro de memória (*memory overflow*) e inviabilizava tanto o processamento quanto a exportação da malha com a textura aplicada. Ao utilizar as máscaras binárias como base no 3D Slicer, foi possível a limpeza adequada dos ruídos e obtenção o fechamento correto da malha poligonal 3D em um tamanho computacionalmente processável para o *hardware* em questão, sem a geração indevida de estruturas internas. Como consequência dessa abordagem, o modelo sólido (fechado) foi exportado sem a coloração dos vértices, enquanto o modelo oco (com espessura de casca) recebeu a aplicação da textura de pele extraída das próprias imagens do VHP, preservando detalhes visuais relevantes, como a tatuagem da bandeira americana presente no cadáver do conjunto de dados.

Em síntese, a compreensão e a correta estruturação do pipeline de treinamento de *Machine Learning* permitiram que o modelo de arquitetura U-Net utilizado neste trabalho alcançasse resultados consistentes na tarefa de segmentação das imagens do *Visible Human Project*, fornecendo os elementos para as etapas subsequentes de reconstrução tridimensional.

Assim, cada fase do pipeline — desde a preparação e o pré-processamento dos dados até a avaliação e a persistência do modelo — contribuiu de forma integrada para o desenvolvimento de um sistema capaz de processar as imagens médicas de maneira automatizada, reduzindo a dependência de intervenções manuais e reforçando a viabilidade da aplicação de técnicas de Aprendizado Profundo no contexto da reconstrução volumétrica de estruturas anatômicas.

9. PERSPECTIVA DE TRABALHOS FUTUROS

Como perspectivas para trabalhos futuros, pretende-se aprofundar a pesquisa em Ciência de Dados com foco no treinamento de modelos de redes neurais aplicados à segmentação de imagens médicas. Entre as direções previstas, destacam-se o teste e a comparação entre diferentes variantes da arquitetura U-Net, como a UNet++ e UNet 3D (ZHOU et al., 2018), avaliando o desempenho de cada abordagem em termos de acurácia, eficiência computacional e qualidade da segmentação obtida.

Acrescentando ainda, explorar a aplicação das técnicas desenvolvidas neste trabalho em domínios além da imagem médica, como o processamento de imagens de caráter agrícola — voltado à detecção de culturas, pragas e análise de solo — e em aplicações relacionadas a previsões climáticas e sensoriamento remoto, áreas nas quais a segmentação semântica de imagens de satélite tem demonstrado resultados promissores na literatura recente (LECUN; BENGIO; HINTON, 2015).

REFERÊNCIAS

AMAZON WEB SERVICES (AWS). **O que é visão computacional?** Disponível em: https://aws.amazon.com/pt/what-is/computer-vision/. Acesso em: 20 abr. 2026.

BASTOS, J. S. F. **Segmentação de imagens RGB**. 2020. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade Estadual de Santa Cruz, Ilhéus, 2020.

BOMFIM, L. S. **Elaboração de um pipeline para a segmentação dos dados referentes ao projeto Visible Human**. 2017. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade Estadual de Santa Cruz, Ilhéus, 2017.

BRAGA, A. P.; CARVALHO, A. P. L. F.; LUDEMIR, T. B. **Fundamentos de redes neurais artificiais.** Rio de Janeiro: LTC, 1998.

CAMPOS, A. S. **Segmentação de imagem RGB utilizando o conjunto** Visible Human. [S. l.]: GitHub, 2022. Disponível em: https://github.com/AllanaCampos/Segmentacao-de-Imagem-RGB-Utilizando-o-conjunto-Visible-Human. Acesso em: 18 mar. 2026.

FACELI, K. et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. Rio de Janeiro: LTC, 2011.

GONZALEZ, R. C.; WOODS, R. E. **Processamento de imagens digitais**. São Paulo: Edgard Blücher, 2000.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 4. ed. New York: Pearson, 2018.

GONZALEZ, R. C.; WOODS, R. E. **Processamento digital de imagens**. 3. ed. São Paulo: Pearson Prentice Hall, 2010.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, **A. Deep Learning**. Cambridge, MA: MIT Press, 2016.

IBM. **Deep learning**. 2026. Disponível em: https://www.ibm.com/br-pt/think/topics/deep-learning. Acesso em: 08 jun. 2026.

IBM. **Image segmentation.** 2026. Disponível em: https://www.ibm.com/br-pt/think/topics/image-segmentation. Acesso em: 14 mar. 2026.

IBM. **Loss function**. 2026. Disponível em: https://www.ibm.com/br-pt/think/topics/loss-function. Acesso em: 17 mar. 2026.

JACCARD, P. **The distribution of the flora in the alpine zone**. New Phytologist, v. 11, n. 2, p. 37-50, 1912.

KERAS. **Whole model saving & loading.** Disponível em: https://keras.io/api/models/model_saving_apis/. Acesso em: 17 jun. 2026.

KIRILLOV, Alexander et al. Segment Anything. In: IEEE/CVF INTERNATIONAL **CONFERENCE ON COMPUTER VISION**, 2023, Paris. Proceedings [...]. [S. l.]: IEEE, 2023. p. 4015–4026. DOI: 10.1109/ICCV51070.2023.00371.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. **Deep learning**. Nature, Londres, v. 521, n. 7553, p. 436–444, 2015. DOI: 10.1038/nature14539. Disponível em: https://www.nature.com/articles/nature14539. Acesso em: 20 abr. 2026.

LITJENS, G. et al. **A survey on deep learning in medical image analysis**. Medical Image Analysis, v. 42, p. 60-88, 2017.

LONG, J.; SHELHAMER, E.; DARRELL, T. F**ully convolutional networks for semantic segmentation.** In: PROCEEDINGS OF THE IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2015. p. 3431-3440.

MILLETARI, Fausto; NAVAB, Nassir; AHMADI, Seyed-Ahmad. V-Net: Fully Convolutional Neural Networks for Volumetric Medical **Image Segmentation.** In: INTERNATIONAL CONFERENCE ON 3D VISION, 4., 2016, Stanford. Proceedings [...]. [S. l.]: IEEE, 2016. p. 565–571. DOI: 10.1109/3DV.2016.79.

MITCHELL, T. M. **Machine Learning.** [S. l.]: McGraw-Hill, 1997.

NASCIMENTO, P. P. L. L. **Quantização de imagens coloridas: estudo das técnicas e metodologias atuais.** 2014. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade Estadual de Santa Cruz, Ilhéus, 2014.

NATIONAL LIBRARY OF MEDICINE (NLM). **Visible Human Project.** Disponível em: https://www.nlm.nih.gov/research/visible/visible_human.html. Acesso em: 13 mar. 2026.

NVIDIA. **UNet 2D Industrial (TF1). NGC Catalog**. Disponível em: https://catalog.ngc.nvidia.com/orgs/nvidia/dle/resources/unet_2d-industrial_tf1/. Acesso em: 07 jul. 2026.

OKTAY, Ozan et al. Attention **U-Net: Learning Where to Look for the Pancreas**. In: MEDICAL IMAGING WITH DEEP LEARNING, 1., 2018, Amsterdam. Proceedings [...]. [S. l.]: PMLR, 2018.RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. U-Net: Convolutional Networks for Biomedical Image Segmentation. In: **INTERNATIONAL CONFERENCE ON MEDICAL IMAGE COMPUTING AND COMPUTER-ASSISTED INTERVENTION,** 18., 2015, Munich. Proceedings [...]. Cham: Springer, 2015. p. 234–241. DOI: 10.1007/978-3-319-24574-4_28.

ROSENBLATT, F. **The perceptron: a probabilistic model for information storage and organization in the brain.** Psychological Review, v. 65, n. 6, p. 386–408, 1958.

SAMMOUDA, R.; SAMMOUDA, M. **Modification of the mean-square error principle to double the convergence speed of a special case of Hopfield neural network used to segment pathological liver color images**. BMC Medical Informatics and Decision Making, London, v. 9, n. 1, p. 1–10, 2009.

SCHWARTZ, W. R.; PEDRINI, H. **Análise de imagens digitais: princípios, algoritmos e aplicações.** São Paulo: Thomson, 2008.

SILVA, V. H. F. **Segmentação de imagens de média e baixa resolução por meio do modelo** Segment Anything. 2024. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Instituto Federal de Educação, Ciência e Tecnologia de São Paulo, São João da Boa Vista, 2024.

STANFORD UNIVERSITY. **Generalized Intersection over Union** (GIoU). Disponível em: https://giou.stanford.edu/. Acesso em: 07 jul. 2026.

WIDROW, B.; HOFF, M. E. **Adaptive switching circuits**. IRE WESCON Convention Record, v. 4, p. 96–104, 1960.

WIKIPÉDIA. **Canny edge detector.** Disponível em: https://en.wikipedia.org/wiki/Canny_edge_detector. Acesso em: 26 jun. 2026.

WIKIPÉDIA. **Ciência de dados.** Disponível em: https://pt.wikipedia.org/wiki/Ciência_de_dados. Acesso em: 20 abr. 2026.

WIKIPÉDIA. **Dice-Sørensen coefficient.** Disponível em: https://en.wikipedia.org/wiki/Dice-Sørensen_coefficient. Acesso em: 13 maio 2026.

WIKIPÉDIA. **HSV**. Disponível em: https://pt.wikipedia.org/wiki/HSV. Acesso em: 08 jun. 2026.

WIKIPÉDIA. **Índice de Jaccard.** Disponível em: https://pt.wikipedia.org/wiki/Índice_Jaccard. Acesso em: 07 jul. 2026.

WIKIPÉDIA. **Rede neural convolucional.** Disponível em: https://pt.wikipedia.org/wiki/Rede_neural_convolucional. Acesso em: 08 jun. 2026.

ZHOU, Zongwei et al. **UNet++: A Nested U-Net Architecture for Medical Image Segmentation.** In: DEEP LEARNING IN MEDICAL IMAGE ANALYSIS, 2018, Granada. Lecture Notes in Computer Science. Cham: Springer, 2018. p. 3–11. DOI: 10.1007/978-3-030-00889-5_1.

APÊNDICE A — MÉTRICAS DETALHADAS DO TREINAMENTO

Tabela 1 – Histórico de métricas de treinamento e validação por época

Época	Acurácia	Coef. Dice	IoU Score	Loss (Perda)	Val. Acurácia	Val. Coef. Dice	Val. IoU Score	Val. Loss	Tx. Aprend. (LR)
1	0.9549	0.9283	0.8753	0.0934	0.2968	0.4534	0.2968	73.9956	0.0010
2	0.9718	0.9504	0.9063	0.0618	0.3231	0.4656	0.3057	1.1038	0.0010
3	0.9708	0.9497	0.9047	0.0624	0.3252	0.4583	0.3013	0.6932	0.0010
4	0.9757	0.9584	0.9205	0.0488	0.9347	0.8983	0.8158	0.3381	0.0010
5	0.9727	0.9506	0.9068	0.0587	0.9241	0.8853	0.7952	0.2272	0.0010
6	0.9745	0.9562	0.9163	0.0520	0.9633	0.9426	0.8916	0.1847	0.0010
7	0.9749	0.9552	0.9154	0.0507	0.9551	0.9218	0.8552	0.1552	0.0010
8	0.9769	0.9596	0.9229	0.0462	0.9658	0.9373	0.8823	0.0950	0.0010
9	0.9762	0.9569	0.9184	0.0487	0.9660	0.9429	0.8923	0.0751	0.0010
10	0.9786	0.9610	0.9256	0.0448	0.9715	0.9464	0.8984	0.0897	0.0010
11	0.9819	0.9689	0.9400	0.0378	0.9810	0.9688	0.9396	0.0402	0.0010
12	0.9842	0.9724	0.9465	0.0337	0.9821	0.9639	0.9306	0.0401	0.0010
13	0.9848	0.9714	0.9457	0.0336	0.9766	0.9613	0.9258	0.0543	0.0010
14	0.9867	0.9764	0.9540	0.0281	0.9868	0.9775	0.9560	0.0292	0.0010
15	0.9871	0.9776	0.9563	0.0277	0.9787	0.9634	0.9294	0.0483	0.0010
16	0.9876	0.9794	0.9596	0.0254	0.9850	0.9742	0.9498	0.0309	0.0010
17	0.9883	0.9792	0.9593	0.0249	0.9847	0.9730	0.9475	0.0334	0.0010
18	0.9882	0.9792	0.9594	0.0253	0.9868	0.9756	0.9525	0.0288	0.0010
19	0.9879	0.9785	0.9580	0.0256	0.9821	0.9668	0.9360	0.0446	0.0010
20	0.9882	0.9790	0.9588	0.0251	0.9760	0.9613	0.9255	0.0708	0.0010
21	0.9880	0.9782	0.9576	0.0263	0.9821	0.9675	0.9372	0.0476	0.0010
22	0.9884	0.9807	0.9622	0.0239	0.9838	0.9707	0.9434	0.0399	0.0010
23	0.9865	0.9746	0.9509	0.0298	0.9750	0.9561	0.9161	0.0658	0.0010
24	0.9876	0.9783	0.9576	0.0263	0.9877	0.9796	0.9601	0.0251	0.0002
25	0.9891	0.9804	0.9616	0.0236	0.9855	0.9735	0.9486	0.0327	0.0002
26	0.9887	0.9810	0.9627	0.0233	0.9872	0.9779	0.9567	0.0277	0.0002

Época	Acurácia	Coef. Dice	IoU Score	Loss (Perda)	Val. Acurácia	Val. Coef. Dice	Val. IoU Score	Val. Loss	Tx. Aprend. (LR)
27	0.9890	0.9811	0.9629	0.0228	0.9864	0.9775	0.9561	0.0279	0.0002
28	0.9895	0.9809	0.9626	0.0226	0.9866	0.9762	0.9536	0.0302	0.0002
29	0.9889	0.9814	0.9634	0.0228	0.9842	0.9731	0.9477	0.0357	0.0002
30	0.9892	0.9812	0.9631	0.0225	0.9870	0.9764	0.9539	0.0284	0.0000
31	0.9897	0.9821	0.9649	0.0217	0.9859	0.9762	0.9536	0.0310	0.0000
32	0.9896	0.9822	0.9650	0.0219	0.9868	0.9757	0.9527	0.0301	0.0000
33	0.9897	0.9813	0.9634	0.0217	0.9870	0.9765	0.9543	0.0302	0.0000
34	0.9894	0.9824	0.9654	0.0217	0.9869	0.9787	0.9582	0.0280	0.0000
35	0.9893	0.9754	0.9561	0.0259	0.9872	0.9779	0.9568	0.0284	0.0000
36	0.9895	0.9822	0.9650	0.0217	0.9861	0.9774	0.9559	0.0300	0.0000
37	0.9898	0.9828	0.9663	0.0210	0.9872	0.9785	0.9579	0.0275	0.0000
38	0.9898	0.9813	0.9634	0.0219	0.9869	0.9765	0.9541	0.0311	0.0000
39	0.9897	0.9817	0.9642	0.0218	0.9869	0.9763	0.9539	0.0299	0.0000

Fonte: Dados do treinamento (2026).